

基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡萄 视频计数方法

吕佳, 冉洁

(1. 重庆师范大学计算机与信息科学学院, 重庆 401331; 2. 重庆市数字农业服务工程技术研究中心, 重庆 401331)

摘要: 针对现有果实计数方法实时性不足, 以及套袋葡萄遮挡和检测噪声导致追踪失败的问题, 该研究提出一种基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡萄视频计数方法。该方法由改进 YOLOv9s 检测模型、自适应卡尔曼滤波追踪算法和划线计数 3 个子方法构成。在检测阶段, 为减少 YOLOv9s 模型的参数量并提升推理速度, 同时增强其在遮挡场景下的检测性能, 设计了 EFEM (efficient feature enhancement module) 优化特征提取, 并引入 SEAM (spatially enhanced attention module) 以提高遮挡情况下的检测性能。在追踪阶段, 为解决因拍摄设备抖动和快速运动等因素引起的检测噪声导致卡尔曼滤波轨迹预测精度下降问题, 提出一种自适应卡尔曼滤波追踪算法。该算法根据检测置信度自动调整噪声估计, 以提高卡尔曼滤波对套袋葡萄轨迹的预测精度, 进而提升追踪性能。在计数阶段, 采用划线计数策略实现对套袋葡萄的自动计数。试验结果表明, 在检测性能方面, 改进后的 YOLOv9s 模型参数量减少了 29.6%, 推理速度达到了 70 帧/s; 在追踪性能方面, 改进后的追踪算法在高阶追踪准确率、多目标追踪准确率及 ID 调和平均数指标上, 分别提升了 4.3、2.2 和 2.5 个百分点; 在计数性能方面, 平均计数精度达到了 80.0%。综上, 该方法在实时追踪与计数方面展现了良好的应用潜力, 可为套袋葡萄收获前的产量估计提供技术支持。

关键词: YOLOv9; 套袋葡萄; 果实追踪; 果实计数; 卡尔曼滤波

doi: 10.11975/j.issn.1002-6819.202412026

中图分类号: S126

文献标志码: A

文章编号: 1002-6819(2025)-10-0195-09

吕佳, 冉洁. 基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡萄视频计数方法[J]. 农业工程学报, 2025, 41(10): 195-203. doi: 10.11975/j.issn.1002-6819.202412026 <http://www.tcsae.org>

LYU Jia, RAN Jie. Counting bagging grape using improved YOLOv9s and adaptive Kalman filter[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(10): 195-203. (in Chinese with English abstract)

doi: 10.11975/j.issn.1002-6819.202412026 <http://www.tcsae.org>

0 引言

葡萄不仅富含多种营养成分, 还具有预防心脑血管疾病等益处^[1]。在葡萄种植管理中, 果农常采用套袋措施减少农药和病虫害对葡萄品质的影响, 从而提高经济效益^[2]。预估葡萄产量不仅有助于果农合理规划采摘、销售和存储^[3], 也为市场供需调节与政府资源配置提供依据^[4-5]。实现精准估产的关键在于对套袋葡萄的准确计数。近年来, 随着深度学习的快速发展, 目标检测与目标追踪算法逐渐被应用到果实计数领域^[6]。然而, 由于移动设备的计算资源有限及拍摄环境的复杂性, 迫切需要一种轻量、高效且稳健的套袋葡萄计数方法。

目标检测算法是实现果实计数的关键技术之一, 主要分为两阶段和一阶段检测算法。两阶段检测算法首先生成一组候选区域, 然后对这些区域进行分类与回归。其中, R-CNN^[7]、Fast R-CNN^[8] 和 Faster R-CNN^[9] 等两阶段检测算法在农业领域应用最为广泛。例如, YAN 等^[10]

通过引入高效通道注意力和多尺度融合特征金字塔对 Faster R-CNN 进行改进, 使得苹果识别平均精度达到了 95.42%。然而, 两阶段检测算法计算资源和时间消耗较大, 推理速度慢, 无法满足农业领域的高实时性要求。相比之下, 一阶段检测算法能直接从图像中进行检测, 推理速度更快, 更适合农业应用场景的需求。在一阶段检测算法中, YOLO 系列检测算法因其高效率 and 准确性, 在提高农业生产效率、优化资源分配和推动可持续农业实践中发挥了重要作用^[11]。QIAO 等^[12] 通过优化 YOLOv5 模型, 提出了一种基于改进 YOLOv5 的红枣计数方法, 实现了在复杂环境中对红枣的高效检测与计数; MA 等^[13] 提出了一种基于改进 YOLOv7-tiny 的轻量级检测算法, 结合多尺度特征融合和轻量化注意力机制, 提高了模型在复杂自然环境中对苹果的检测精度。然而, 上述方法仅实现了单张图片的果实计数, 单张图片提供视野有限, 无法覆盖整颗果树, 限制了在大规模果树计数任务中的准确性和实用性。

为克服单张图片在果实计数中的局限性, 研究者开始在视频数据流中应用目标追踪算法, 实现果实计数^[14]。目标追踪算法利用上一帧目标的位置信息, 定位当前帧中的同一目标, 从而实现连续追踪^[15]。基于卡尔曼滤波^[16] (Kalman filtering, KF) 的追踪算法, 因其能够保留被遮

收稿日期: 2024-12-04 修订日期: 2025-04-20

基金项目: 重庆市高校创新研究群体 (CXQT20015); 重庆市研究生科研创新项目 (CYS240362)

作者简介: 吕佳, 博士, 教授, 研究方向为计算机视觉与机器学习、数字农业工程。Email: lvjia@cqnu.edu.cn

挡果实的预测框,并在果实重新出现时进行匹配,减少了因重复检测造成的计数误差,而被广泛应用。高芳芳等^[17]基于 YOLOv4-tiny 与 KF 实现苹果视频计数,有效避免了重复计数。然而,该方法在果实匹配时忽略了果实的外观特征,影响了匹配的准确性。为此,GE 等^[18]基于 YOLOv5 模型和 DeepSort 追踪算法^[19]提出了一种视觉目标追踪网络。该网络利用 DeepSort 提取果实的外观特征信息,增强了网络的目标关联匹配能力。由于 DeepSort 仅考虑高置信度检测框,忽略了低置信度检测框,易导致目标丢失及 ID 切换。为了解决这一问题,LI 等^[20]采用改进的 ByteTrack 追踪算法^[21]对火龙果进行追踪,该算法保留了低置信度检测框,提高了火龙果的追踪性能和平均计数精度。吕佳等^[22]进一步优化 KF,将非极大值抑制操作后置,并引入相机运动补偿,缓解了人工拍摄不稳导致的干扰。然而,ByteTrack 引入额外的操作,增加了计算开销,限制其在移动设备上的实时性。

尽管基于 KF 的目标追踪算法在果实计数领域得到广泛应用^[23-25],但在套袋葡萄计数的实际应用中,仍存在以下问题:1) 现有果实检测模型都侧重于检测精度的提升,忽略了在真实场景下的实时性与实用性,难以满足资源受限场景下的应用需求;2) 套袋后的葡萄体积增大,果实之间相互遮挡或被葡萄叶片遮挡,导致检测困难;3) 拍摄设备抖动和快速不规则运动会引起检测噪声,进而影响 KF 对轨迹的预测,降低追踪性能。为了解决套袋葡萄计数中存在的上述问题,本文提出了一种基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡萄视频计数方法。

1 数据采集和预处理

1.1 数据采集

本文构建了一个套袋葡萄的图像和视频数据集,数据采集地点为重庆市璧山区派登科技示范园区,地理坐标为经度 106.221°、纬度 29.753°、高度 353 m。数据采集时间分别为 2022 年 7 月 22 日和 2023 年 9 月 1 日,采集工具为 OPPO Reno6pro+ 和红米 K40 智能手机。为了获得套袋葡萄在自然环境中真实地形态,选择了一天中的不同时间段进行了拍摄,包括清晨、午后和傍晚,以捕捉不同光照条件下的多角度外观。此外,拍摄还覆盖了多个视角,如正视、俯视、仰视和侧面,全面展现葡萄的外观特征。拍摄时,研究人员沿葡萄种植行分段进行记录,最终收集了 700 张高分辨率原始图像和 6 个视频。图像的分辨率分别为 4 000×3 000 像素和 4 096×3 072 像素,视频则以 1920×1 080 像素的高清分辨率、MP4 格式记录,帧率为 30 帧/s,每段视频时长约 20 s。

1.2 图像增强与标注

本文将 700 张原始图像按照 7:2:1 的比例随机划分为训练集 490 张、验证集 140 张和测试集 70 张。另外,6 个套袋葡萄视频用于评估所提计数方法的计数性能。为了增强检测模型的鲁棒性和泛化性,本文在训练集中应用了高斯噪声、翻转和饱和度调整等图像增强方法,

将训练集的图像扩增至 2 100 张。通过饱和度调整、亮度增强与减弱,使模型能够适应多种光照条件下的情况。镜像翻转、高斯噪声以及图像翻转等操作使模型能够学习套袋葡萄在不同角度和视角下的特征,从而提高模型应对复杂环境的能力。图 1 为原始图像增强后的示例。




图 1 图像增强效果

Fig.1 Image enhancement effect

本文采用 Make Sense 工具对原始图像和增强处理后的图像进行了标注,通过矩形框精确标记图像中套袋葡萄的位置,并导出符合 YOLO 标准的数据集格式,其中包含套袋葡萄矩形框的尺寸和中心点位置信息。本文还使用 DarkLabel 工具对视频进行逐帧标注,为捕捉套袋葡萄从出现到消失的连续变化,在每一帧上绘制出套袋葡萄的最小外接矩形框,以确保准确追踪套袋葡萄的动态变化。

2 套袋葡萄视频计数方法

为解决现有方法在检测实时性、遮挡条件下检测准确性及检测噪声处理方面的不足,本文提出了一种基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡萄视频计数方法。该方法的整体流程如图 2 所示。首先,将输入的套袋葡萄视频分解为视频帧序列。其次,利用改进后的检测模型 (ES-YOLOv9s) 对每一帧进行检测。ES-YOLOv9s 通过引入高效特征增强模块 (efficient feature enhancement module, EFEM) 和空间增强注意力模块 (spatially enhanced attention module, SEAM) 对 YOLOv9s 模型进行改进,并使用套袋葡萄图像数据集进行训练,使得该模型能够精准识别出每一帧中的套袋葡萄。随后,使用自适应 KF 追踪 (adaptive Kalman filter tracking, AKFT) 算法对不同帧中的同一套袋葡萄进行关联匹配,并为每个套袋葡萄分配唯一 ID。在关联匹配过程中,AKFT 通过自适应 KF 根据检测置信度自动调整 KF 的噪声估计,提高套袋葡萄轨迹预测精度,从而实现对套袋葡萄的准确追踪。最后,通过划线计数策略实现对套袋葡萄的自动计数,即套袋葡萄中心点碰撞到计数线时,套袋葡萄数量自动加 1。

2.1 ES-YOLOv9s 检测模型

YOLOv9s^[27] 作为 YOLO 系列的实时检测算法之一,通过引入可编程梯度信息 (programmable gradient

information, PGI) 解决了深度网络中信息瓶颈问题, 在识别各种大小和复杂性的目标时表现出色。因此, 本文选择了 YOLOv9s 检测模型作为套袋葡萄视频计数的基础检测模型。

在实际应用中, 检测模型的参数量不仅影响套袋葡萄的检测实时性, 还对计数设备的计算资源提出较高的要求。然而, 目前大多数检测模型主要关注果实检测精度的提升, 而未充分考虑模型的实时性和计数设备的需求, 这限制了检测模型在实际场景中的应用效果。为了平衡模型的参数量、检测精度和推理速度, 本文设计了 EFEM, 以替换 YOLOv9s 原有的 RepNCSPPELAN4 模块。同时, 针对套袋处理后的葡萄体积增大, 容易与其他葡萄、葡萄叶片、葡萄藤等物体产生重叠遮挡, 本文引入

了 SEAM 增强模型对于遮挡套袋葡萄的检测。改进后的 ES-YOLOv9s 模型结构如图 3 所示。





图 2 套袋葡萄视频计数整体流程

Fig.2 Overall workflow of bagged grape video counting



注: Conv 表示卷积操作; Cat 表示特征拼接; Aconv 是一种结合平均池化和卷积操作的模块; SPPELAN 表示一种空间金字塔池化结构; Upsample 表示上采样操作; SEAM 是空间增强注意力模块; EFEM 是高效特征增强模块。

Note: Conv denotes the convolution operation; Cat denotes feature concatenation; Aconv is a module that combines average pooling and convolution operations; SPPELAN refers to a spatial pyramid pooling structure; Upsample denotes the upsampling operation; SEAM is the spatially enhanced attention module; EFEM is the efficient feature enhancement module.

图 3 ES-YOLOv9s 模型结构图

Fig.3 ES-YOLOv9s model architecture diagram


2.1.1 EFEM 模块

由于 YOLOv9s 中 RepNCSPPELAN4 模块大量使用标准卷积 (convolution, Conv), 导致其参数量较大且推理速度较慢, 这使得 YOLOv9s 部署到移动设备上时难以实现高实时性检测。Conv 需要对所有特征图进行卷积操作, 计算复杂度高。在神经网络中不同特征图之间信息高度

相似或相关, 特别是经过套袋处理后的葡萄体积增大且轮廓更加明显, 其特征信息可能在不同特征图之间重复出现。因此, 本文设计了 EFEM, 通过 FasterNet^[28] 模块仅对套袋葡萄部分特征图进行学习, 从而实现高效的特征提取和更快的推理速度, 其结构如图 4a 所示。

FasterNet 模块旨在通过减少冗余计算和内存访问来

高效地提取空间特征,其结构如图4b所示。首先,部分卷积 (partial convolution, PConv) 通过仅在部分输入通道上执行卷积操作来有效降低计算负担,从而实现高效的空间特征提取, PConv 和 Conv 如图4c所示。随后,两个 1×1 卷积负责在保持空间分辨率不变的前提下,对通道维度进行处理以调整通道数。在这两个 1×1 卷积之间,进行了归一化操作 (batch normalization, BN) 和 ReLU 激活,其中 BN 有助于加速模型的收敛过程并维持训练稳定性,而 ReLU 则通过引入非线性来增强模型的表达力。此外,采用了残差连接将输入直接添加到输出中,这不仅保留了原始输入特征,而且有助于缓解深层网络中的梯度消失问题,确保信息的有效传递与特征重用。



注: PConv 为部分卷积; Conv 为标准卷积; h 和 w 为输入特征图的高度和宽度; c 为输入特征图的通道数; c_p 为参与卷积的通道数; * 表示卷积操作。Note: PConv is partial convolution; Conv is standard convolution; h and w are the height and width of the input feature map; c is the number of channels of the input feature map; c_p is the number of channels involved in the convolution; * denotes the convolution operation.

图4 高效特征增强模块、FasterNet 模块结构及部分卷积与标准卷积对比

Fig.4 Comparison of efficient feature enhancement module, FasterNet module structure and partial convolution with standard convolution


2.1.2 SEAM 模块

套袋处理后的葡萄体积增大,容易与其他葡萄、葡萄叶片、葡萄藤等物体产生重叠遮挡。由于套袋葡萄遮挡区域的特征信息不完整,SEAM 通过学习套袋葡萄遮挡区域与未遮挡区域之间的关系,预测并补偿被遮挡的部分特征,从而提高对遮挡套袋葡萄的检测。

SEAM 结构如图5所示。首先,将输入的套袋葡萄特征图经过通道和空间混合模块 (channel-spatial mixed module, CSMM) 进行处理,以学习空间维度和通道之间的相关性。其次,使用一个两层全连接网络以融合每个通道的信息,从而增强通道间的连接性。最后,将 SEAM 的输出与原始特征图相乘,作为注意力权重,使模型能够更有效地处理目标遮挡问题。

在 CSMM 中,套袋葡萄特征图被分割成不同大小的图像序列块,随后将这些块线性映射并展平为一维向量。然后,采用带有残差连接的 3×3 深度卷积进行处理。深度卷积以逐通道的方式操作,即对每个通道进行独立的卷积运算。尽管深度卷积能够有效学习不同通道的重要

性并减少参数量,但其忽略了通道间信息的交互关系。为了弥补这一不足,随后通过 1×1 逐点卷积将不同深度卷积的输出进行组合。



注: Patch=6、Patch=7 和 Patch=8 表示输入的特征图被分为 6×6 、 7×7 和 8×8 的小块。

Note: Patch=6, Patch=7, and Patch=8 indicate that the input feature map is divided into 6×6 , 7×7 , and 8×8 patches, respectively.

图5 空间增强注意力模块结构图

Fig.5 Spatially enhanced attention module structure diagram

2.2 AKFT 追踪算法

ByteTrack 追踪算法^[21]引入 Byte 的数据关联方法,不仅针对高置信度检测框进行处理,还对低置信度检测框进行二次关联匹配。该算法在保持实时性的同时,显著提升了目标追踪性能。因此,本文选择 ByteTrack 追踪算法作为套袋葡萄追踪阶段的基础追踪算法。

ByteTrack 追踪算法采用 KF 进行轨迹预测。KF 是一种用于预测和估计系统状态的方法^[16],其过程主要包括两个步骤:预测和更新。在预测步骤中,追踪算法基于上一时刻的状态值和运动模型来预测当前时刻的状态,如式(1)所示。在更新步骤中,将预测结果与当前时刻的实际观测值相结合,以获得更准确的状态估计,如式(2)所示。然而,由于 KF 主要适用于简单且匀速的运动预测,在拍摄条件不稳定或目标运动非匀速的情况下,检测结果包含较多噪声干扰,导致其预测精度下降,进而影响整体的追踪性能。为了解决这一问题,本文提出了自适应 KF,以提高在复杂拍摄条件下追踪的准确性与稳定性。

$$\begin{cases} \hat{\mathbf{x}}_{t|t-1} = \mathbf{A}\hat{\mathbf{x}}_{t-1|t-1} + \mathbf{B}\mathbf{u}_t \\ \mathbf{P}_{t|t-1} = \mathbf{A}\mathbf{P}_{t-1|t-1}\mathbf{A}^T + \mathbf{Q} \end{cases} \quad (1)$$

式中 $\mathbf{A}$ 是状态转移矩阵, $\mathbf{B}$ 是控制输入矩阵, $\mathbf{u}_t$ 是控制向量, $\mathbf{Q}$ 是过程噪声协方差矩阵, $\hat{\mathbf{x}}_{t|t-1}$ 是第 t 帧时刻的状态矩阵, $\mathbf{P}_{t|t-1}$ 是预测的状态协方差矩阵。

$$\begin{cases} \mathbf{K}_t = \mathbf{P}_{t|t-1}\mathbf{H}^T(\mathbf{H}\mathbf{P}_{t|t-1}\mathbf{H}^T + \mathbf{N})^{-1} \\ \hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t(\mathbf{z}_t - \mathbf{H}\hat{\mathbf{x}}_{t|t-1}) \\ \mathbf{P}_{t|t} = (\mathbf{I} - \mathbf{K}_t\mathbf{H})\mathbf{P}_{t|t-1} \end{cases} \quad (2)$$

为了验证 ES-YOLOv9s 在套袋葡萄检测中的速度和精度, 本文将 YOLOv5s、YOLOv7-tiny^[29]、YOLOv8s、YOLOv9s^[27]、YOLOv10s^[30] 与 ES-YOLOv9s 进行了对比试验。表 1 展示了不同检测模型的对比结果。试验结果表明, YOLOv9s 在 P 和 A_p 上取得最佳, 达到了 98.5% 和 96.9%。这是因为 YOLOv9s 通过引入 PGI 解决信息在经过多层网络丢失的问题, 使检测模型在经过多层网络学

习后依然能利用浅层网络中的关键信息。然而, 引入 PGI 增加了网络的复杂和计算开销, 导致 YOLOv9s 推理速度显著低于其他模型。因此, 本文设计了 EFEM 对其进行改进, 改进后的 ES-YOLOv9s 不仅在 A_p 和 R 方面表现优异, 同时具备较高的推理速度, 证明 ES-YOLOv9s 可作为实现套袋葡萄追踪与计数的检测模型。此外, 为更直观地评估各模型性能差异, 本文还选择了背景噪声、套袋葡萄重叠以及叶片遮挡比较明显的三张图进行了检测可视化。可视化结果如图 7 所示, YOLOv5s、YOLOv7-tiny、YOLOv8s、YOLOv9s 和 YOLOv10s 均存在不同程度的漏检和误检, 而 ES-YOLOv9s 能够精准且稳定地框

定套袋葡萄, 无论是在密集情况还是复杂背景条件下, 均展现出良好的检测效果。


表 1 不同检测模型的对比结果

Table 1 Comparison results of different detection models

模型 Model	$P/\%$	$R/\%$	$A_p/\%$	FPS/(帧·s ⁻¹)
YOLOv5s	95.1	90.7	96.0	35
YOLOv7-tiny	95.2	92.7	95.2	26
YOLOv8s	89.3	89.5	94.0	62
YOLOv9s	98.5	87.4	96.9	51
YOLOv10s	93.6	87.2	93.3	65
ES-YOLOv9s	95.3	93.1	96.9	70

注: FPS 为每秒帧数, P 为精度, R 为召回率, A_p 为平均精度。

Note: FPS is frames per second, P is precision, R is recall, A_p is average precision.



注: 绿色圆圈表示漏检的套袋葡萄; 黄色箭头表示误检的套袋葡萄。

Note: Green circles indicate missed bagged grapes; yellow arrows indicate misdiagnosed bagged grapes.

图 7 检测结果可视化

Fig.7 Visualization of detection results

EFEM 和 SEAM 对 ES-YOLOv9s 性能的影响如表 2 所示。首先, EFEM 旨在降低模型参数量并提高推理速度, 在将 EFEM 替换 YOLOv9s 中 RepNCSPeLAN4 模块后, 模型的参数量减少了 32.7%, FLOPs 减少了 11.8G, FPS 提升至 70 帧/s, 同时 R 值也有所提高。然而, EFEM 仅对输入特征图的部分进行特征提取, 导致 P 和 A_p 值略微下降。其次, 单独在 YOLOv9s 中加入 SEAM 会导致各个指标下降。由于 SEAM 增强了对遮挡套袋葡萄的学习, 遮挡套袋葡萄存在更多噪声干扰, 从而影响模型的性能。最后, 将 EFEM 和 SEAM 同时应用于 YOLOv9s 时, 得到改进的 ES-YOLOv9s 检测模型。

表 2 不同模块对 ES-YOLOv9s 性能的影响

Table 2 Influence of different modules on performance of ES-YOLOv9s

EFEM	SEAM	$P/\%$	$R/\%$	$A_p/\%$	参数量 Parameters/ M	浮点运算数 Floating point operations/G	FPS/ 帧·s ⁻¹
—	—	98.5	87.4	96.9	9.8	39.9	51
√	—	98.2	88.1	96.7	6.6	28.1	70
—	√	94.5	89.8	96.5	10.0	40.8	46
√	√	95.3	93.1	96.9	6.9	29.0	70

注: “—”表示未使用该模块; “√”表示使用了该模块。

Note: “—” indicates that the module is not used; “√” indicates that the module is used.

与 YOLOv9s 相比, ES-YOLOv9s 参数量下降了 29.6%, FLOPs 减少了 10.9G, FPS 提升了 20 帧/s, 同

时 A_p 值持平, R 值提升了 5.7 个百分点。试验结果证明, ES-YOLOv9s 在不牺牲精度的情况下实现了轻量化和提高推理速度。

3.4 套袋葡萄追踪与计数

3.4.1 不同追踪算法对比结果

为了评估 AKFT 在套袋葡萄数据集上的追踪性能, 将其与 Sort^[31]、DeepSort^[19]、DeepMot^[32]、UAVmot^[33]、ByteTrack^[21] 和 NMS-ByteTrack^[22] 追踪算法进行了对比试验。试验结果如表 3 所示, AKFT 在 HOTA、MOTA 和 IDF1 指标上分别达到了 58.6%、63.6% 和 78.8%, 均优于其他追踪算法。其原因在于, Sort 在设计时未考虑目标遮挡和外观特征信息, 其运动估计和数据关联仅依赖检测框的位置和大小。DeepSort 和 DeepMot 在 Sort 基础上引入了卷积神经网络和循环神经网络用于提取套袋葡萄外观信息, 并结合运动信息提高追踪算法性能。然而, DeepSort 和 DeepMot 仅保留高置信度检测框, 忽略了低置信度检测框。尽管低置信度检测框的可靠性较低, 但可能包含实际存在的套袋葡萄, 将其丢弃会导致部分套袋葡萄追踪失败。为了进一步提升目标关联精度, UAVmot 引入了 ID 特征更新模块以增强目标的关联匹配, 但在处理外观高度相似的套袋葡萄时, 相邻目标的特征相似性仍可能影响关联匹配的准确性, 限制了整体的追踪性能。由于低置信度检测框可能包含套袋葡萄, ByteTrack

通过将低置信度检测框进行二次关联匹配, 考虑了所有检测框, 从而减少了套袋葡萄追踪丢失。NMS-ByteTrack 在 ByteTrack 的基础上, 通过将非极大值抑制操作后置、改进 KF 以及引入相机运动补偿, 解决套袋葡萄遮挡和人工拍摄不稳定等问题, 提高追踪性能。然而, 引入相机运动补偿和改进 KF 增加了算法的计算复杂度, 对计算资源的要求较高, 导致其追踪实时性较低。由于 ByteTrack 依赖传统的 KF 进行轨迹预测, 传统 KF 未对检测噪声进行处理, 导致其对套袋葡萄轨迹预测精度低。因此, 本文提出自适应 KF 对 ByteTrack 追踪算法进行了改进, 并将 ES-YOLOv9s 引入到 ByteTrack 追踪算法中, 形成本文提出的 AKFT 追踪算法。该追踪算法根据检测置信度自动调整噪声估计, 在确保实时追踪的同时, 提高 KF 对套袋葡萄轨迹的预测精度。试验结果显示, AKFT 追踪算法在 HOTA、MOTA 和 IDF1 指标上分别较 ByteTrack 提高了 4.3、2.2 和 2.5 个百分点, 验证了其在套袋葡萄追踪的有效性。

表 3 不同追踪算法在套袋葡萄数据集上的对比结果

Table 3 Comparison results of different tracking algorithms

追踪方法 Tracking method	HOTA/%	MOTA/%	IDF1/%	IDSW	A _{FPS} /(帧·s ⁻¹)
Sort	51.0	59.9	67.8	13	35
DeepSort	51.5	58.1	71.5	17	27
DeepMot	39.4	54.3	44.4	28	30
UAVmot	53.5	59.9	75.4	3	37
ByteTrack	54.3	61.4	76.3	3	35
NMS-ByteTrack	57.0	60.0	70.0	0	22
AKFT	58.6	63.6	78.8	6	35

注: HOTA 为高阶追踪准确率; MOTA 为多目标追踪准确率; IDF1 为 ID 调和平均数; IDSW 为 ID 切换次数; A_{FPS} 为平均每秒帧数。

Note: HOTA is the high-order tracking accuracy; MOTA is the multi-target tracking accuracy; IDF1 is identification F1-score; IDSW is ID switch; A_{FPS} is the average frames per second.

为了验证不同改进对套袋葡萄追踪性能的影响, 本文以 YOLOv9s 作为检测阶段的基础模型, ByteTrack 作为追踪阶段的基础模型, 试验结果如表 4 所示。首先, EFEM 和 SEAM 是对 YOLOv9s 检测模型进行改进。EFEM 旨在降低 YOLOv9s 检测模型参数量和提升推理速度, 对追踪性能影响较小。SEAM 增强了对遮挡套袋葡萄的检测能力, 相比 YOLOv9s 检测模型, 在 HOTA 上提升了 0.9 个百分点; 但遮挡套袋葡萄检测结果存在更多噪声, 导致 MOTA、IDF1 分别下降了 3.4、1.5 个百分点, IDSW 增加了 3 次。其次, 自适应 KF 是对 ByteTrack 追踪算法的改进, 根据检测噪声动态调整 KF 对套袋葡萄的预测, 相比 ByteTrack, 在 HOTA、MOTA 和 IDF1 提升了 1.5、1.6 和 1.4 个百分点, IDSW 减少了 2 次。图 8 展示了 ByteTrack 改进前后 KF 预测框的可视化对比。结果表明, 在遮挡情况下, 改进后的预测框更加精准, 长宽比例和尺寸更好地框住了套袋葡萄。最后, 将使用 EFEM 和 SEAM 改进的 ES-YOLOv9s 检测模型引入到采用自适应 KF 的 ByteTrack 追踪算法中, 形成 AKFT。该算法不仅增强对遮挡套袋葡萄的检测, 还能根据检测置信度自动调整噪声估计。与基础模型相比, AKFT 在 HOTA、MOTA 和 IDF1 上提升了 4.3、2.2 和 2.5 个百分点, 证明了 AKFT 在追踪性能方面的有效性。

表 4 不同改进对套袋葡萄追踪性能的影响

Table 4 Impact of different improvements on the tracking performance of bagged grapes

EFEM	SEAM	自适应卡尔曼滤波 Adaptive Kalman filtering	HOTA/%	MOTA/%	IDF1/%	IDSW
—	—	—	54.3	61.4	76.3	3
√	—	—	55.0	58.0	74.8	6
—	√	—	55.2	60.3	75.4	6
—	—	√	55.8	63.0	77.7	1
√	√	—	56.0	57.9	73.4	3
√	—	√	54.7	58.5	73.4	6
—	√	√	56.5	62.3	76.4	8
√	√	√	58.6	63.6	78.8	6




图 8 改进前后的预测框可视化对比

Fig. 8 Visualization comparison of prediction boxes before and after improvement

3.4.2 套袋葡萄实时计数

为评估划线计数策略的准确性, 本文在 6 个套袋葡萄视频上进行了试验, 并将结果与人工计数进行了对比。为了确保人工计数的准确性, 每个视频由两名研究人员独立计数, 通过在计算机上逐帧观看视频, 详细记录每个套袋葡萄出现和消失的情况, 并取两者的平均值以减少人为误差。结果如表 5 所示。试验表明该计数策略与人工计数的结果相近, 证实了套袋葡萄视频计数方法的有效性。

表 5 人工计数与划线计数比较

Table 5 Comparison between manual count and line count

计数方法 Counting method	视频 1 Video one	视频 2 Video two	视频 3 Video three	视频 4 Video four	视频 5 Video five	视频 6 Video six	平均计数精度 Average counting accuracy/%
人工计数 Manual counting	22	7	22	11	13	19	—
划线计数 Line count	18	7	11	10	9	17	80.0

4 结 论

本文以套袋葡萄为研究对象, 提出了基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡萄视频计数方法, 实现了套袋葡萄在线实时追踪与计数。该研究主要结论如下:

1) 检测阶段, 本文设计了 EFEM 并引入 SEAM, 对 YOLOv9s 进行了改进。改进 ES-YOLOv9s 在 A_p 和 R 分别达到了 96.9% 和 93.1%。同时, 其推理速度达到了 70 帧/s。与原 YOLOv9s 相比, ES-YOLOv9s 的参数量减

少了 29.6%, FLOPs 降低了 10.9G, 推理速度提升了 20 帧/s。

2) 追踪阶段, 本文采用自适应 KF 根据检测置信度自动调整噪声估计, 提出了 AKFT。相比其他 6 种追踪算法, AKFT 在 H_{OTA} 、 M_{OTA} 、 I_{DF1} 等指标上显著优于其他追踪算法, 分别到达了 58.6%、63.6% 和 78.8%。相较于基础追踪算法提高了 4.3、2.2 和 2.5 个百分点。

3) 计数阶段, 本文采用划线计数策略对套袋葡萄进行计数。结果表明, 该策略与人工计数的结果相近, 平均精度达到了 80.0%。证实本文提出的基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡萄视频计数方法可为套袋葡萄收获前的产量估计提供参考。

本文仅对套袋葡萄实现实时追踪与计数, 未来将考虑扩展到其他果实种类。此外, 针对实际生产过程中, 模型轻量化、便捷性以及算法稳健等方面可以进一步改进, 以实现更加精准的果实追踪与计数。

[参 考 文 献]

- [1] SABRA A, NETTICADAN T, WIJEKON C. Grape bioactive molecules, and the potential health benefits in reducing the risk of heart diseases[J]. *Food Chemistry: X*, 2021, 12: 100149.
- [2] KARAJEH M R. Pre-harvest bagging of grape clusters as a non-chemical physical control measure against certain pests and diseases of grapevines[J]. *Organic Agriculture*, 2018, 8(3): 259-264.
- [3] HE L, FANG W, ZHAO G, et al. Fruit yield prediction and estimation in orchards: A state-of-the-art comprehensive review for both direct and indirect methods[J]. *Computers and Electronics in Agriculture*, 2022, 195: 106812.
- [4] 杨志强, 彭韵, 石水平. 战略购销协议、客户需求稳定性与企业投资效率——基于供应链管控视角的分析[J]. 上海财经大学学报, 2024, 26(4): 107-123.
YANG Zhiqiang, PENG Yun, SHI Shuiping. Strategic purchase and sales agreements, customer demand stability, and enterprise investment efficiency: From the perspective of supply-chain management and control[J]. *Journal of Shanghai University of Finance and Economics*, 2024, 26(4): 107-123. (in Chinese with English abstract)
- [5] 王晓东. 在统筹发展和安全中完善重要商品储备制度: 以农产品为视角的分析[J]. 中国农村经济, 2022, 5: 2-19.
WANG Xiaodong. Improving important commodity reserve system in overall development and security: An analysis from the perspective of agricultural products[J]. *Chinese Rural Economy*, 2022, 5: 2-19. (in Chinese with English abstract)
- [6] ZHANG W, WANG J, LIU Y, et al. Deep-learning-based in-field citrus fruit detection and tracking[J]. *Horticulture Research*, 2022, 9: uhac003.
- [7] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Columbus, OH, USA: IEEE, 2014: 580-587.
- [8] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE International Conference on Computer Vision. Piscataway, NJ: IEEE, 2015: 1440-1448.
- [9] REN S, He K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2016, 39(6): 1137-1149.
- [10] YAN Z, ZHANG H, LI L. An integrated target recognition method based on improved Faster-RCNN for apple detection, counting, localization, and quality estimation[C]//2024 IEEE 4th International Conference on Power, Electronics and Computer Applications. Shenyang, China: IEEE, 2024: 1234-1240.
- [11] FU H, GUO Z, FENG Q, et al. MSOAR-YOLOv10: Multi-Scale occluded apple detection for enhanced harvest robotics[J]. *Horticulture*, 2024, 10(12): 1246.
- [12] QIAO Y, HU Y, ZHENG Z, et al. A counting method of red jujube based on improved YOLOv5s[J]. *Agriculture*, 2022, 12(12): 2071.
- [13] MA L, ZHAO L, WANG Z, et al. Detection and counting of small target apples under complicated environments by using improved YOLOv7-tiny[J]. *Agronomy*, 2023, 13(5): 1419.
- [14] WANG Z, WALSH K, KOIRALA A. Mango fruit load estimation using a video based MangoYOLO-kalman filter-hungarian algorithm method[J]. *Sensors*, 2019, 19(12): 2742.
- [15] LUO W, XING J, MILAN A, et al. Multiple object tracking: A literature review[J]. *Artificial Intelligence*, 2021, 293(4): 103448.
- [16] KALMAN R E. A new approach to linear filtering and prediction problems[J]. *Journal of Basic Engineering*, 1960, 82(1): 35-45.
- [17] 高芳芳, 武振超, 索睿, 等. 基于深度学习与目标跟踪的苹果检测与视频计数方法[J]. 农业工程学报, 2021, 37(21): 217-224.
GAO Fangfang, WU Zhenchao, SUO Rui, et al. Apple detection and counting using real-time video based on deep learning and object tracking[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2021, 37(21): 217-224. (in Chinese with English abstract)
- [18] GE Y, LIN S, ZHANG Y, et al. Tracking and counting of tomato at different growth period using an improving YOLO-DeepSort network for inspection robot[J]. *Machines*, 2022, 10(6): 489.
- [19] WOJKE N, BEWLEY A, PAULUS D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE International Conference on Image Processing. Beijing, China: IEEE, 2017: 3645-3649.
- [20] LI X, WANG X, ONG P, et al. Fast recognition and counting method of dragon fruit flowers and fruits based on video stream[J]. *Sensors*, 2023, 23(20): 8444.
- [21] ZHANG Y, SUN P, JIANG Y, et al. Bytetrack: Multi-object tracking by associating every detection box[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 1-21.
- [22] 吕佳, 张翠萍, 刘琴, 等. 基于自纠正 NMS-ByteTrack 的套袋葡萄估产方法[J]. 农业工程学报, 2023, 39(13): 182-190.
LYU Jia, ZHANG Cuiping, LIU Qin, et al. Bagged grape yield estimation method using a self-correcting NMS-ByteTrack[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(13): 182-190. (in Chinese with English abstract)
- [23] SHEN L, SU J, HE R, et al. Real-time tracking and counting of grape clusters in the field based on channel pruning with YOLOv5s[J]. *Computers and Electronics in Agriculture*, 2023, 206: 107662.
- [24] 刘鑫, 马本学, 李玉洁, 等. 基于改进 YOLOv7-ByteTrack 的干制哈密大枣缺陷检测与计数系统[J]. 农业工程学报, 2024, 40(3): 303-312.
LIU Xin, MA Benxue, LI Yujie et al. Defect detection and counting system of dried hami dates based on improved YOLOv7-ByteTrack[J]. *Transactions of the Chinese Society of*

- Agricultural Engineering (Transactions of the CSAE), 2024, 40(3): 303-312. (in Chinese with English abstract)
- [25] 殷慧军, 王宝丽, 景运革, 等. 基于改进 YOLOv7 的无人机航拍视频西瓜计数方法[J]. 农业工程学报, 2024, 40(19): 124-134.
- YIN Huijun, WANG Baoli, JING Yunge, et al. Improved YOLOv7 method for counting watermelons in UAV aerial videos[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(19): 124-134. (in Chinese with English abstract)
- [26] YU Z, HUANG H, CHEN W, et al. Yolo-facev2: A scale and occlusion aware face detector[J]. *Pattern Recognition*, 2024, 155: 110714.
- [27] WANG C Y, YE H I, MARK LIAO H Y. Yolov9: Learning what you want to learn using programmable gradient information[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2025: 1-21.
- [28] CHEN J R, KAO S H, HE H, et al. Run, don't walk: Chasing higher FLOPS for faster neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, Canada: IEEE, 2023: 12021-12031.
- [29] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, BC, Canada: IEEE, 2023: 7464-7475.
- [30] WANG A, CHEN H, LIU L, et al. Yolov10: Real-time end-to-end object detection[J]. *Advances in Neural Information Processing Systems*, 2024, 37: 107984-108011.
- [31] BEWLEY A, GE Z, OTT L, et al. Simple online and realtime tracking[C]//2016 IEEE International Conference on Image Processing, Beijing, China: IEEE, 2017: 3645-3649.
- [32] XU Y, OSEP A, BAN Y, et al. How to train your deep multi-object tracker[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, WA, USA: IEEE, 2020: 6787-6796.
- [33] LIU S, LI X, LU H, et al. Multi-object tracking meets moving UAV[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans, LA, USA: IEEE, 2022: 8876-8885.

Counting bagging grape using improved YOLOv9s and adaptive Kalman filter

LYU Jia , RAN Jie

(1. College of Computer and Information Science, Chongqing Normal University, Chongqing 401331, China; 2. Chongqing Digital Agricultural Service Engineering Technology Research Center, Chongqing 401331, China)

Abstract: Grapes can be one type of the fruit with the widest cultivation area, the highest yield, and extremely high economic value in China. Among them, bagging techniques can be often employed to reduce the impact of pests and diseases on the grape quality during the harvest period. An accurate yield estimation can greatly contribute to the plan picking, sales, and storage, in order to reduce the economic losses caused by supply-demand mismatches. The accurate counting of bagged grapes can be required before yield estimation. However, the existing fruit counting can usually suffer from insufficient real-time detection and tracking failure, due to the occlusion of bagged grapes and unprocessed detection noise. In this study, video counting was proposed for the bagged grapes using an improved YOLOv9s and adaptive Kalman filter. Three modules were included: the improved YOLOv9s detection model, an adaptive Kalman filter tracking algorithm, and a line-drawing counting. In detection, the original RepNCSPELAN4 module in YOLOv9s was replaced with an efficient feature enhancement module (EFEM), in order to reduce the number of model parameters for the inference speed. The performance of the improved YOLOv9s model was enhanced for sufficient real-time detection. The EFEM was designed to selectively learn from the partial feature maps of the bagged grapes, thereby enabling efficient feature extraction and faster inference. The FasterNet module was specifically utilized to efficiently extract the spatial features, in order to minimize the redundant computation and memory access. A spatially enhanced attention module (SEAM) was introduced to further improve the detection performance under occlusion conditions. The SEAM was used to learn the relationship between occluded and unoccluded areas. The occluded features were predicted and compensated to thereby improve the detection accuracy of bagged grapes under full and partial occlusion. In tracking, an adaptive Kalman filter algorithm was proposed to reduce the detection noise caused by camera shake and rapid movement. The accuracy of Kalman filter trajectory prediction was promoted after tracking. Noise estimation was automatically adjusted, according to the detection confidence. A line-drawing counting was used for the real-time counting of bagged grapes; Once the center of the bagged grape was collided with a virtual counting line, the number of bagged grapes increased by one. The experimental dataset was collected from the PaiDengTe Technology Demonstration Park in Bishan District, Chongqing, China. There were 700 original images of bagged grapes and six video clips. The dataset was randomly divided into a training set of 490 images, a validation set of 140 images, and a test set of 70 images at a ratio of 7 : 2 : 1. The six video clips were used to test the counting performance. Some image enhancement techniques were applied to the training set during training, such as saturation adjustment, brightness variation, image mirroring, and Gaussian noise addition, thereby expanding the training set to 2100 images. The robustness and generalization of the detection model were enhanced after enhancement. Experimental results show that the best performance of the improved YOLOv9s model (ES-YOLOv9s) outperformed five other models. The highest mean average precision and recall were 96.9% and 93.1%, respectively, while there was an inference speed of 70 frames per second. Compared with the original YOLOv9s, the ES-YOLOv9s reduced the number of parameters by 29.6%, and the number of floating-point operations decreased by 10.9G, whereas, the frame rate was improved by 20 frames per second. In terms of tracking performance, the adaptive Kalman filter tracking algorithm achieved 58.6%, 63.6%, and 78.8% in the higher-order tracking accuracy, multi-object tracking accuracy, and ID harmonic mean metrics, respectively, thus representing improvements of 4.3, 2.2, and 2.5 percentage points over ByteTrack. In terms of counting performance, line-drawing counting was achieved with an average accuracy of 80.0%, compared with manual counting. In conclusion, the video counting of bagged grapes with the improved YOLOv9s and Kalman filter also demonstrated better application potential in real-time tracking and counting. The finding can provide technical support for the pre-harvest yield estimation of bagged grapes.

Keywords: YOLOv9; bagged grapes; fruit tracking; fruit counting; Kalman filtering