

# 无人机遥感视频影像结合改进 YOLO11 的柑橘追踪计数方法

翁海勇<sup>1,2,3</sup>, 杜璐<sup>1,2</sup>, 张博昱<sup>1,2</sup>, 苏磊磊<sup>1,2</sup>, 许金钗<sup>1,2</sup>,  
肖桂森<sup>1,2</sup>, 孙大伟<sup>3,4</sup>, 叶大鹏<sup>1,2\*</sup>

(1. 福建农林大学机电工程学院, 福州 350002; 2. 福建省农业信息感知技术重点实验室, 福州 350002; 3. 农业农村部东南丘陵山地农业装备重点实验室(部省共建), 杭州 310021; 4. 浙江省农业科学院农业装备研究所, 杭州 310021)

**摘要:** 针对无人机遥感尺度下, 柑橘估产过程中存在跟踪计数误差大的问题, 该研究提出一种轻量化 YOLO11-PMSL 模型与 ByteTrack-DIoU 算法相融合的无人机视频流柑橘果实跟踪计数方法。首先, 在 YOLO11n 架构的基础上, 通过重构特征金字塔结构, 将检测头层级精简为 P2~P4 三级结构, 以增强微小目标感知能力; 其次, 引入 C3k2-MSEIE (C3k2-multi-scale edge information enhance) 多尺度边缘增强模块, 通过自适应尺度融合与轮廓强化机制, 以提升果实轮廓表征能力; 进一步, 采用 SIOU (scylla-IoU) 损失函数替代 CIOU (complete-IoU) 损失函数, 引入方向敏感性约束以期提升检测框定位质量与训练稳定性, 最后, 通过 LAMP (layer adaptive magnitude-based pruning) 方法模型剪枝, 去除冗余的权重, 以减少参数量和浮点运算量, 压缩模型体积。在 ByteTrack-DIoU 算法中嵌入区域计数防抖机制, 进一步解决遮挡导致的 ID 跳变问题。结果表明, 改进后 YOLO11-PMSL 目标检测模型精确率 ( $P$ )、均值平均精度 ( $mAP_{0.5}$ ) 分别提高 3.3、9.3 个百分点。剪枝后, 与原始的 YOLO11n 相比, 在保持精度总体提升的同时, 模型的参数量、浮点运算量和模型大小分别降低了 86.05%、26.98% 和 76.36%, 检测速度由 84.83 帧/s 提高到 140.12 帧/s。与传统 SORT、DeepSORT 和 BotSORT 算法相比, ByteTrack-DIoU 算法的多目标跟踪准确率分别提高 5.5、5.7 和 4.3 个百分点, 跟踪计数平均精度达 88.4%。该方法可准确实现果园柑橘果实的跟踪计数, 为柑橘产量预测提供有效的技术方案。

**关键词:** 无人机; 遥感; 柑橘; YOLO11n; ByteTrack; 计数

doi: 10.11975/j.issn.1002-6819.202508166

中图分类号: S24

文献标志码: A

文章编号: 1002-6819(2026)-07-0182-11

翁海勇, 杜璐, 张博昱, 等. 无人机遥感视频影像结合改进 YOLO11 的柑橘追踪计数方法[J]. 农业工程学报, 2026, 42(7): 182-192. doi: 10.11975/j.issn.1002-6819.202508166 <http://www.tcsae.org>

WENG Haiyong, DU Lu, ZHANG Boyu, et al. Citrus tracking and counting using UAV remote sensing video imagery with improved YOLO11[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(7): 182-192. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202508166 <http://www.tcsae.org>

## 0 引言

柑橘产量数据的精准获取是果园精细化管理的核心基础<sup>[1]</sup>。在传统的估产实践中, 多以人工计数的方式进行, 存在费时耗力, 成本高以及估测结果并不准确等问题。因此, 研究快速且实用的柑橘产量预测方法具有重要意义。

早期农作物计数研究主要依赖传统图像处理技术。TRAN 等<sup>[2]</sup>采用图像分割、边界确定、形状分析和重叠分析, 以计算每棵树的火龙果数量。BEHERA 等<sup>[3]</sup>以迭代方式实现霍夫圆变换 (hough circle transform, HCT) 和颜色阈值, 以检测和计数每个苹果果实。然而上述算法, 对复杂背景和光照变化的鲁棒性差, 难以处理多目标场景及遮挡问题。近年来, 深度学习技术在果实计数领域

得到了广泛应用。ZHU 等<sup>[4]</sup>通过深度学习的检测模型来计算树木图像中的果实数量, 考虑包括果实数量、树木修剪强度和三个不同的图像视图, 采用 XGBoost 模型根据果实计数估计单棵树的产量。LI 等<sup>[5]</sup>基于 MHSA-YOLOv8 构建的番茄果实成熟度分级模型, 构建计数模型的精确度为 99%。为克服二维图像在空间信息表达上的局限, 研究者开始引入三维信息, 以增强模型的空间感知能力。ZINE-EL-ABIDINE 等<sup>[6]</sup>提出 3D 彩色点云处理管道, 通过冬季与收获期点云对齐将苹果分配给单棵树, 实现了高于 95% 的分配准确率, 为茂密果园单树苹果计数提供可行方案。ZHANG 等<sup>[7]</sup>基于三维点云多特征融合, 采用 SVM 分类、加权 KNN 平滑优化, 结合集聚-分裂分层聚类计数, 石榴果实计数准确率和召回率分别为 78.15% 和 87.74%, 提升自然环境下计数准确性。虽然以上研究均取得了较高精度, 但这些方法大多基于静态图像处理, 缺乏实时性, 且数据采集过程耗时费力, 难以实现果园大范围的快速动态监测。此外, 捕捉三维信息的设备昂贵、操作复杂、数据处理缓慢, 实用性受到极大限制。

为解决上述问题, 研究者开始尝试基于目标检测与多目标跟踪技术相结合的动态计数方法。WANG 等<sup>[8]</sup>使用 YOLO 实现对芒果的检测, 并结合卡尔曼滤波

收稿日期: 2025-08-20 修订日期: 2026-01-22

基金项目: 农业农村部东南丘陵山地农业装备重点实验室(部省共建)项目(KFKT2024008); 福建省工信厅人工智能应用场景项目项目(KLY24501XA); 福建农林大学科技创新专项基金(KFB24041A)

作者简介: 翁海勇, 博士, 副教授, 研究方向为农作物光学传感及装备。

Email: hyweng@fafu.edu.cn

※通信作者: 叶大鹏, 博士, 教授, 研究方向为智能农业装备。

Email: dpy@fafu.edu.cn

和匈牙利算法,实现对芒果的实时计数。高芳芳等<sup>[9]</sup>利用改进的匈牙利算法和 YOLOV4-tiny 进行苹果匹配,算法改进后的跟踪置信度大大增强。然而,这种跟踪方法只对 30 s 内的视频进行计数。GE 等<sup>[10]</sup>提出了一种称为 YOLO-deepsort 的视觉对象跟踪网络,用于识别和计数不同生育时期的番茄。但是由于环境复杂其检测不稳定,检测过程中会晃动,目标跟踪和计数效果不好,需进一步提高应对复杂环境的能力。VIVEROS 等<sup>[11]</sup>利用 YOLOv5 模型对甜椒进行实时目标检测、分类和定位,并结合 DeepSORT 算法进行高效跟踪,有效克服了遮挡、叶子和树枝等环境影响,准确率达到 85.7%。LIN 等<sup>[12]</sup>针对阴影和光照影响计数精度的问题,对 YOLOv5s 进行改进,并结合 DeepSORT 实现跟踪计数。改进后模型的多目标跟踪准确率达 90.83%,但模型对小目标的感知能力有限,且模型整体轻量化水平与实时性难以满足大规模果园的高效计数需求。ZHENG 等<sup>[13]</sup>提出基于无人机的柑橘计数,该方法实现了无人机在线计数管道在弱光场景的应用,在白天傍晚的场景下其误差均值仅为 9.81%,实现昼夜场景计数,提升了检测精度与运行时长。但该系统轻量化程度有待提升。殷慧军等<sup>[14]</sup>提出 YOLOv7-GCSF 与 DeepSORT 融合的无人机视频西瓜计数方法,计数精度达 96.3%,但因西瓜体积较大、生长形态相对规则,其遮挡场景复杂度较低,研究未考虑严重遮挡问题。ByteTrack 能有效利用低置信度检测框进行目标关联,从而在遮挡、密集及晃动场景中保持连续轨迹,吕佳等<sup>[15]</sup>提出一种基于自纠正 NMS-ByteTrack 的套袋葡萄计数方法,平均计数精度达到 82.8%。刘鑫等<sup>[16]</sup>设计一种结合改进 YOLOv7 与 ByteTrack 的干制哈密大枣在线检测与计数系统,改进模型平均检测精度达 98.03%,配套计数模型准确率为 90.12%。吕佳等<sup>[17]</sup>提出一种基于 EMO-YOLOv5s 的双关联套袋葡萄串实时检测与计数方法,模型优化后平均检测精度 96.5%,平均计数精度达 93.1%。这些研究表明目标检测与多目标跟踪技术在农业计数领域具有巨大潜力,为柑橘估产提供了重要基础。

然而,果园大范围快速动态监测的实际应用场景,对模型的部署环境提出了严苛要求:模型需能够适配低功耗、小体积的移动边缘计算平台以实现现场实时处理。但现有模型的参数量与计算量较大,其在资源受限的边缘平台上难以满足实时性运行需求。针对边缘端资源受限的部署特性,适用模型需具备三项核心条件:一是模型体积小,适配边缘硬件存储容量,二是计算复杂度低,适配硬件算力水平,可实现数据的实时处理;三是参数量少,便于在资源有限的边缘硬件上高效部署。

针对柑橘的追踪计数主要存在以下 3 个问题:

- 1) 检测目标过小以及复杂背景干扰,导致果实漏检、误检率高,直接影响计数起点;
- 2) 枝叶晃动、果实密集造成的频繁遮挡极易导致目标丢失(ID switch)和轨迹断裂,难以保证长时间、连续、准确的 ID 保持与计数;
- 3) 现有高性能模型计算量大,难以在资源受限的移动边缘平台上实时处理。

针对上述问题,本研究对 YOLO11n 的网络结构进

行改造,提升目标检测精度,控制模型复杂度,兼顾精度与效率。同时,对 ByteTrack 算法进行改进,旨在提高追踪的精度,从而实现对柑橘果实的精准计数,为柑橘果园产量预测提供高效可靠的技术支持。

## 1 数据集构建

### 1.1 图像采集

本研究以“脐橙 52 号”柑橘(Navel Orange 52)为研究对象。为构建具有代表性的数据集,于 2024 年 11 月中上旬,在中国福建省福州市闽侯县白沙镇(东经 119.04°,北纬 26.22°)的原味综合农场柑橘种植基地,开展数据采集,拍摄路线如图 1 所示。数据采集设备选用大疆精灵 Phantom 4 无人机(DJI Phantom 4),支持 4K 分辨率视频录制。为确保获取全面反映果实状态的数据,无人机飞行设定如下:采用俯仰角约为 45°的倾斜视角,该视角可有效避开上层冠层叶片对低层柑橘的垂直遮挡,飞行离地高度保持在 2 m 以上,既能保证镜头对低层柑橘的清晰成像,又能避免飞行过程中与植株冠层发生碰撞,与两侧植株冠层保持最小水平距离 0.5 m,可减少冠层边缘叶片对镜头的遮挡干扰,以 0.5 m/s 的恒定速度平稳飞行,确保相机曝光稳定,避免因速度过快导致低层柑橘图像模糊、细节丢失,共采集有效视频片段 30 段。所获取视频的分辨率为 4 096×2 160 像素,帧率为 23.98 帧/s。拍摄无人机遥感视频后,对实际果园中的果树,按行实施人工逐果计数。




图 1 数据采集线路图

Fig.1 Data acquisition circuit diagram

### 1.2 数据标注

考虑到视频中相邻帧间存在高度相似性,为避免数据冗余并提升训练效率,本研究使用 OpenCV 库对视频进行处理,每隔 15 帧提取一帧图像,共获得 3 549 张分辨率为 4 096×2 160 像素的高清静态图像,采用 LabelLme 标注工具对图像进行精细标注。将标注好的 3 549 张图像及其标注文件按照 7:2:1 的比例随机划分为训练集、验证集和测试集。

## 2 模型构建

### 2.1 基准模型

选用 YOLO11n 作为核心目标检测的基准模型。YOLO11<sup>[18]</sup>作为新一代实时目标检测框架,在检测精度与推理速度上取得了显著提升。而 YOLO11n 作为该系列的轻量化版本,在模型复杂度与计算资源需求上进行了优化,能够适配资源受限边缘计算平台的共性部署需求(模型体积小、计算复杂度低、参数量少),为实时检测提供了潜在的高效解决方案。然而,在对于柑橘的实际无人机航拍场景中,原始 YOLO11n 模型在检测上面临背景复杂、果实聚集与相互遮挡现象以及由于拍摄

距离导致的目标像素占比极小等严峻挑战。这些因素共同作用,导致模型容易出现对小尺寸柑橘果实的漏检和误检。因此,需要对 YOLO11n 模型进行改进以满足柑橘估产对检测鲁棒性的要求。

## 2.2 YOLO11-PMSL 目标检测模型

本研究对原始 YOLO11n 模型进行架构优化,优化后的 YOLO11-PMSL 模型见图 2。


1) 特征金字塔重构: 将检测头层级精简为 P2~P4 三级结构,通过移除深层冗余模块并融合高分辨率浅层

特征,以增强微小目标感知能力;

2) 边缘感知增强: 将基础卷积模块升级为 C3k2-MSEIE 多尺度边缘增强架构,通过自适应尺度融合与轮廓强化机制,以提升果实轮廓表征能力;

3) 损失函数优化: 采用 SIoU 损失函数替代传统边界框回归方法,引入方向敏感性约束以提升检测框定位质量与训练稳定性。

4) 模型剪枝: 通过 LAMP 方法模型剪枝,去除冗余的权重以,减少参数数量和浮点运算量,压缩模型体积。



注:  $k$  为卷积核大小,  $s$  为步长。  
Note:  $k$  is the kernel size, and  $s$  is the stride

图 2 YOLO11-PMSL 模型结构图  
Fig.2 YOLO11-PMSL network structural diagram

### 2.2.1 小目标检测

YOLO11n 通过双向特征传递路径整合不同层级的特征表达,配置三级检测头 (图 3a),实现对多尺度目标的适应性检测。尽管深层卷积能提取抽象语义信息,但原始图像经高倍率下采样后,微小目标的几何信息严重衰减,导致关键特征丢失。为提升对柑橘果实的检测能力,本研究在 YOLO11n 中引入 P2 高分辨率检测层,引入 P2 高分辨率特征层后,模型在柑橘测试集上的  $mAP_{0.5}$  与召回率显著提升,充分证明了 P2 层在增强小目标特征表征方面的有效性。该扩展虽能强化小目标感知能力,但需处理更高维度的浅层特征,显著增加计算负荷。鉴于航拍场景中检测主体均为小尺度目标,深层 P5 检测头的高阶语义提取功能贡献有限,却占据大量计算资源。通过解耦冗余的 P5 检测模块及其关联卷积层,可削减运算开销,降低计算复杂度,并减小模型的参数量,实现检测精度与计算复杂度之间的平衡。改进后的网络结构 (图 3b) 移除 P5 检测头后,在颈部网络层对生成 P3 的中间特征图进行上采样,将其与骨干网络首个 C3k2 模块输出的高分辨率

特征图进行通道对齐与特征拼接,拼接后经过 C3k2 模块进行特征融合,生成新的高分辨率特征层 P2,并同步构建对应的 P2 检测头,最终形成 P2~P4 三级检测体系。该架构通过聚焦骨干网络浅层的高粒度特征,增强对细小像素目标的轮廓辨识能力,同时压缩了参数量,实现检测精度与计算效率的协同优化。


### 2.2.2 C3k2\_MSEIE 模块

在无人机获取柑橘冠层过程中,密集枝叶遮挡、果实重叠以及光照变化等因素导致果实边缘特征模糊,原始 YOLO 模型的标准 C3k2 模块的固定感受野设计在应对柑橘果实尺度差异时缺乏灵活性,尤其对部分遮挡果实和小型果实的轮廓捕捉能力有限,制约了检测精度。针对该问题,本研究将多尺度边缘增强机制引入骨干网络 (backbone) 的 C3k2,构建了 C3k2\_MSEIE 模块。该模块位置如图 2 所示, C3k2\_MSEIE 模块替换了原来的 C3k2 模块,具体位于 backbone 的第 2、4、6 层。

EdgeEnhancer 模块是以分离并强化高频边缘信息为核心思路的边缘增强机制。EdgeEnhancer 模块结构如图 4 所示。该模块首先通过对输入特征图进行平均池化

操作，实现平滑处理，以提取其中的低频背景信息。接着，将原始输入特征图与此平滑后的低频信息进行差值运算，从而分离并凸显出高频边缘信息。这些被提取出的边缘信息会经过一个卷积层操作，以进一步强化其边

缘响应。最后，经过增强处理的边缘特征被加回到原始输入特征图中，在保留原始特征信息的基础上，强化图像边缘细节，在遮挡场景下增强柑橘果实的圆形轮廓响应，有效解决边缘模糊问题。



注：P1、P2、P3、P4、P5 为 5 个不同尺寸的特征图。

Note: P1, P2, P3, P4, and P5 are five feature maps of different sizes.

图 3 小目标检测层改进

Fig.3 Improvements of the small target detection layer

MSEIE 模块构建使用自适应平均池化构建多尺度并行架构以增强边缘特征表征能力，实现多尺度边缘特征提取。MSEIE 模块结构如图 5 所示。该模块对同一输入的特征图，首先通过自适应池化层构建  $3\times 3$ 、 $6\times 6$ 、 $9\times 9$  和  $12\times 12$  四种尺度的特征提取分支，提取蕴含不同感受野的上下文信息，然后将每个分支先采用  $1\times 1$  卷积压缩通道至输入  $1/4$ ，消除特征冗余，再通过分组卷积提取空间信息，随后经过上采样操作将特征图恢复到与输入相同大小，最后经边缘增强模块优化轮廓响应，通过通道拼接形成包含不同尺度边缘信息的特征图，再经卷积模

块对拼接后的特征进行跨通道信息融合与优化。这种设计使网络能捕获更多的局部细节，克服了传统固定感受野的局限性，输出兼具细节感知与语义理解能力的增强特征，特别适用于复杂场景下的小目标检测任务。




图 4 EdgeEnhancer 模型结构图

Fig.4 EdgeEnhancer model structure diagram




图 5 MSEIE 模型结构图

Fig.5 MSEIE model structure diagram

C3k2\_MSEIE 模块使用多尺度边缘信息增强模块 MSEIE 优化了 C3k2，将 C3k 瓶颈块中的普通卷积替换为多尺度边缘信息增强 MSEIE 模块，得到了优化后的 C3k\_MSEIE，然后将 C3k\_MSEIE 模块嵌入到 C3k2 中，得到了 C3k2\_MSEIE 模块。该模块通过多尺度边缘增强机制提升了细粒度特征的提取能力。既强化了局部细节表达能力，增强了对果实轮廓提取能力，又保留了果实整体形态特征，可在果实密集区域展现更优的特征表达

能力。C3k2\_MSEIE 模块结构如图 6 所示。

### 2.2.3 SIOU 损失函数

YOLO11n 模型默认采用的 CIoU<sup>[19]</sup> 损失函数，然而，对于航拍图像中有效像素区域有限且轮廓易受环境干扰而模糊的柑橘小目标，CIoU 在充分建模其细微几何特征方面存在局限，可能制约定位准确性的进一步提升。为解决上述问题，本研究在 YOLO11n 框架中引入 SIOU<sup>[20]</sup> (Scylla-IoU) 损失函数替代 CIoU。SIOU 损失函数及维

度计算式如下:

1) 角度损失 (angle cost,  $\Lambda$ ):

$$\Lambda = 1 - 2 \cdot \sin 2 \left[ \arcsin \frac{c_h}{\sigma} - \frac{\pi}{4} \right] = \cos \left[ 2 \cdot \left( \arcsin \frac{c_h}{\sigma} - \frac{\pi}{4} \right) \right] \quad (1)$$

式中  $c_h$  为真实框和预测框中心点的高度差,  $\sigma$  为真实框和预测框中心点的距离。

$$\frac{c_h}{\sigma} = \sin \alpha \quad (2)$$

$$\sigma = \sqrt{(b_{c_x}^{gt} - b_{c_x})^2 + (b_{c_y}^{gt} - b_{c_y})^2} \quad (3)$$

$$c_h = \max(b_{c_y}^{gt}, b_{c_y}) - \min(b_{c_y}^{gt}, b_{c_y}) \quad (4)$$

式中  $(b_{c_x}^{gt}, b_{c_y}^{gt})$  为真实框中心坐标,  $(b_{c_x}, b_{c_y})$  为预测框中心坐标, 当  $\alpha$  为  $\frac{\pi}{2}$  或 0 时, 角度损失为 0, 在训练过程中若  $\alpha < \frac{\pi}{4}$ , 则最小化  $\alpha$ , 否则最小化  $\beta$ 。

2) 距离损失 (distance cost,  $\Delta$ ):

$$\Delta = \sum_{t=x,y} (1 - e^{-\gamma p(t)}) = 2 - e^{-\gamma p(x)} - e^{-\gamma p(y)} \quad (5)$$

$$\begin{cases} p(x) = \left( \frac{b_{c_x}^{gt} - b_{c_x}}{c_w} \right)^2, \\ p(y) = \left( \frac{b_{c_y}^{gt} - b_{c_y}}{c_h} \right)^2, \\ \gamma = 2 - \Lambda \end{cases} \quad (6)$$

式中  $(c_w, c_h)$  为真实框和预测框最小外接矩形的宽和高;  $p(t)$  是真实框和预测框中心点偏移量的尺度归一化平方值, 用于量化预测框与真实框在对应方向上的位置偏差程度。

3) 形状损失 (shape cost,  $\Omega$ ):

$$\Omega = \sum_{t=w,h} (1 - e^{-W(t)})^\theta = (1 - e^{-W(w)})^\theta + (1 - e^{-W(h)})^\theta \quad (7)$$

$$\begin{cases} W(w) = \frac{|w - w^{gt}|}{\max(w, w^{gt})} \\ W(h) = \frac{|h - h^{gt}|}{\max(h, h^{gt})} \end{cases} \quad (8)$$

式中  $(w, h)$  和  $(w^{gt}, h^{gt})$  分别为预测框和真实框的宽和高,  $\theta$  控制对形状损失的关注程度;  $W(t)$  是预测框与真实框在宽度和高度方向上的归一化绝对差异, 用于量化形状失配程度。

4) IoU 损失 (IoU):

$$\text{IoU} = \frac{A \cap B}{A \cup B} \quad (9)$$

式中  $A$  为预测框区域,  $B$  为真实框区域,  $A \cap B$  为预测框与真实框的交集区域,  $A \cup B$  为预测框与真实框的并集区域。

5) SIOU 损失函数 ( $\text{Loss}_{\text{SIOU}}$ ):

$$\text{Loss}_{\text{SIOU}} = 1 - \text{IoU} + \frac{\Delta + \pi}{2} \quad (10)$$

SIOU 损失函数通过整合距离度量、方向感知、形态约束及交并比优化 4 个维度构建多要素协同的几何建模框架, 在空间关系建模中同步考量边界框中心点偏移、重叠区域覆盖度、宽高比例差异以及整体形状分布特性, 形成对目标几何关系的综合表征机制; 针对无人机俯拍场景中易受背景干扰的小尺度目标, 该设计通过强化边缘分布建模与形状匹配能力可提升检测框定位精度并降

低误检率, 同时引入的方向敏感性设计增强了对目标方向特征的捕获能力, 鉴于航拍视角动态变化及目标自然朝向多样性, 该机制使预测框与实际目标方位可能实现更紧密的空间对齐, 从而在方向复杂场景中增强检测稳定性, 上述多维度优化要素通过全局约束框架协同作用, 使该损失函数在优化 IoU 指标的同时可能促进边界框回归精度提升、加速模型收敛过程并增强对目标几何特性及方向变化的适应能力, 为密集小目标的农业视觉检测任务提供新的优化路径。




图 6 C3k2\_MSEE 模块结构

Fig.6 C3k2-MSEE module structure

#### 2.2.4 模型剪枝

在优化 YOLO11 网络架构的过程中, 检测精度的提升伴随着计算资源的显著增加。为协调模型复杂度与表征能力之间的平衡, 本研究引入基于层自适应幅度的剪枝 (layer adaptive magnitude-based pruning, LAMP) [21]。LAMP 的核心在于建立跨层统一的重要性评估体系。与传统剪枝方法的分层独立阈值设定不同, LAMP 提出全局重要性评分机制, LAMP 评分计算式如下:

$$\text{score}(u, W) = \frac{(W[u])^2}{\sum_{v \in \Omega_u} (W[v])^2} \quad (11)$$

式中  $\text{score}(u, W)$  表示 LAMP 评分,  $W[u]$  表示权重张量中索引  $u$  处的标量值,  $W[v]$  表示权重张量中索引  $v$  处的标量值,  $\Omega_u$  定义为  $u$  索引后的权重子集。

式 (11) 通过归一化处理消除层间权重规模差异, 使评分值具有跨层可比性。LAMP 通过动态阈值实现全局优化, 该方法确保在预设约束下, 自动确定各层的最佳剪枝强度, 无需人工干预层间压缩比例。LAMP 的自适应机制显著降低超参数调优复杂度。通过全局稀疏约束参数控制, 模型可自动生成层间非均匀的剪枝方案。这种特性使算法在保持原网络表征能力的前提下, 有效降低计算复杂度。同时, LAMP 结构化剪枝方案与主流硬件平台不存在本质性兼容冲突, 其核心原因在于该剪枝策略仅针对模型通道维度实施结构化裁剪, 并未改变原始模型的算子类型与核心计算逻辑, 只要剪枝后模型的算子集合仍在目标硬件的支持范围内, 即可正常导出并完成推理部署。

### 2.3 柑橘实时计数模型

#### 2.3.1 ByteTrack 的柑橘目标跟踪算法

在柑橘果实目标跟踪任务中, 传统的 ByteTrack 算法相似度度量上采用交并比 (IoU) 指标进行轨迹匹配。然而 IoU 仅考虑两个框的重叠区域, 无法直接反映中心点偏移的程度, 在果园场景中, 无人机移动、风力导致

果实晃动或枝叶部分遮挡都可能导致相邻帧果实检测框的中心点发生偏移。该度量方式易导致匹配错误、身份切换或轨迹丢失等问题。

为解决 IoU 在空间位置度量上的不足，进一步提升果实跟踪在复杂果园环境下的准确性和稳定性，本研究将 ByteTrack 中的相似度度量由 IoU 改进为 DIoU (distance-IoU)。

DIoU 在 IoU 的基础上增加了一个惩罚项 (Penalty Term)，该惩罚项直接最小化预测框 ( $B_{pred}$ ) 与检测框 ( $B_{det}$ ) 中心点之间的归一化距离，其计算式为

$$DIoU = IoU - \frac{\rho^2(b_{pred}, b_{det})}{c^2} \quad (12)$$

式中  $\rho^2(b_{pred}, b_{det})$  是  $B_{pred}$  中心点  $(x_{pred}, y_{pred})$  与  $B_{det}$  中心点  $(x_{det}, y_{det})$  之间的欧氏距离。 $c$  是能同时覆盖  $B_{pred}$  和  $B_{det}$  的最小闭包区域的对角线长度。 $\rho^2 / c^2$  项将中心点距离归一化到  $[0, 1)$  区间。

DIoU 作为距离度量，使用  $(1 - DIoU)$  作为关联的距离代价。DIoU 值范围在  $(-1, 1]$ ，值越大表示两个框空间位置越接近。

ByteTrack 的核心在于其“两次关联”策略，将 DIoU 替换 IoU 后，可增强对复杂果园环境的鲁棒性。DIoU 对中心点距离的显式优化，使得算法能更准确地关联发生位置偏移的果实检测框，减少因位置跳变导致的跟踪丢失或 ID 切换。DIoU 在第二次关联中，通过同时考虑重叠区域和中心点距离，能更可靠地将这些低分但位置基本正确的检测框关联回被短暂遮挡的果实轨迹，维持轨迹连续性，减少因遮挡造成的漏计。DIoU 通过中心点距离信息，有助于更精确地区分相邻果实并关联到正确的轨迹上，减少因密集造成的 ID 切换。ByteTrack-DIoU 的流程图如图 7 所示。

### 2.3.2 区域计数机制

由于柑橘果树呈行状分布，果实密集且存在重叠遮

挡，单帧检测易产生重复计数或漏检。传统逐帧累加方法无法区分新出现的果实与已跟踪目标，导致计数误差累积。因此，本研究设计了一种基于虚拟检测线的区域计数防抖机制。该机制的核心是为每个跟踪目标（果实）维护一个独立的状态机（如图 8），并根据其边界框中心点与预定义检测区域的相对位置关系，进行稳健的计数决策。区域计数算法优势在于：首先，采用物体中心点连续  $N$  帧（ $N$  的取值在算法的灵敏度和鲁棒性之间进行权衡。 $N$  值过小，则防抖效果不佳； $N$  值过大，则可能导致快速移动的目标漏计。本文参考目标跟踪领域中常用的轨迹平滑与确认策略，如在黄鹤飞<sup>[22]</sup>的区域计数机制中，使用 5 帧来确认一个新轨迹的诞生，以避免虚警。因此，本机制设  $N=5$ 。）位于区域内才触发计数的策略，避免果实因风吹摆动产生的边界抖动误判；其次，区分“进入”与“离开”双通道计数逻辑，适配无人机平行于果树行飞行的作业模式。





图 7 ByteTrack-DIoU 的流程图  
Fig.7 ByteTrack-DIoU flowchart



注：状态机包含以下几种状态：OUTSIDE，目标位于检测区域之外；ENTERING，目标首次从外部进入检测区域，进入“进入检测”流程；INSIDE，目标已确认进入区域，并被计数（针对进入流程）；LEAVING，目标从内部离开检测区域，进入“离开检测”流程。

Note: The state machine contains the following states: OUTSIDE, the target is outside the detection area; ENTERING, the target enters the detection area from the outside for the first time and enters the "Enter Detection" process; INSIDE, the target has confirmed entry into the zone and has been counted (for the entry process); LEAVING, the target leaves the detection area from the inside and enters the "leaving detection" process.

图 8 区域计数防抖机制状态机  
Fig.8 Area counting anti-shake mechanism state machine

当无人机扫描每行果树时,果实依次通过检测区域,该算法能精准记录通过虚拟检测线的果实数量,消除因果实重叠导致的重复计数。其工作流程为当改进模型检测到果实并输出边界框后,ByteTrack-DIoU 算法为每个果实分配唯一 ID 并建立跨帧轨迹。随后,区域计数器对每条轨迹进行状态分析:算法记录每个果实首次出现时的位置状态,若首次出现在检测区域外,则启动“进入检测”流程;若首次出现在区域内,则启动“离开检测”流程。

## 2.4 试验环境及评价指标

### 2.4.1 试验环境

本试验使用的设备平台配置为,CPU 处理器型号为 Intel Core i7-13700kf@5.4 GHz,为 16 核 24 线程的桌面处理器,GPU 型号为 NVIDIA GeForce RTX 3060,显存为 16 GB,内存为 64 GB。操作系统为 Linux Debian 12.2.0,计算架构为 CUDA 12.9,编程语言为 Python 3.10.16,深度学习框架为 Pytorch 2.4.0。训练轮次为 800,批处理大小为 8,优化器为 Adam (adaptive moment estimation),初始学习率为 0.001。

### 2.4.2 评价指标

本研究采用多维度指标综合量化模型性能。目标检测效能通过精确率 (precision,  $P$ )、召回率 (recall,  $R$ ) 与均值平均精度 (mean average precision,  $mAP_{0.5}$ ) 进行评价,三者分别反映误检控制能力、漏检规避能力及综合检测精度。模型计算复杂度则采用浮点运算量 (floating point operations, FLOPs) 和参数量 (parameters) 表征,同时以帧率 (frames per second, FPS) 衡量模型的实时处理能力

多目标跟踪性能通过三类核心指标验证:多目标跟踪准确率 (multiple object tracking accuracy, MOTA) 评估目标跨帧连续追踪的可靠性,体现轨迹完整性维持水平;多目标跟踪精确率 (multiple object tracking precision, MOTP) 则量化预测边界框与真实标注框的空间重合精度,反映定位偏差程度。身份识别 F1 分数 (identification F1 score, IDF1) 评估多目标跟踪算法性能,衡量跟踪器在整个视频序列中保持目标身份 (ID) 一致性的能力。MOTA<sup>[23]</sup>、MOTP 和 IDF1<sup>[24]</sup> 计算式为

$$MOTA = 1 - \frac{\sum_t (F_{N_t} + F_{P_t} + I_{DSW_t})}{\sum_t G_{T_t}} \quad (13)$$

$$MOTP = \frac{\sum_{t,i} \delta_{t,i}}{\sum_t C_t} \times 100\% \quad (14)$$

$$IDF1 = \frac{\sum_t 2T_{P_t}}{\sum_t (2T_{P_t} + F_{N_t} + F_{P_t})} \times 100\% \quad (15)$$

式中  $T_{P_t}$  为目标身份正确匹配数,  $F_{N_t}$  为目标身份漏报数,  $F_{P_t}$  为目标身份误报数,  $I_{DSW_t}$  为目标 ID 变化的次数,  $G_{T_t}$  为目标出现的总数,  $\delta_{t,i}$  为跟踪框与检测框之间的重叠率,  $C_t$  为当前帧匹配成功的目标数;  $t$  为测试视频帧序列。

采用平均计数精度 (mean counting accuracy, MCA) 作为计数估算的核心评价依据,其数值正相关于计数准

确性。该指标定义为预测计数与真实计数的归一化绝对误差补偿值, MCA<sup>[25]</sup> 计算式为

$$MAC = \frac{1}{n} \sum_{i=1}^n \frac{P_i}{G_i} \times 100\% \quad (16)$$

式中 MAC 为平均计数精度,  $P_i$  为检测到的目标数,  $G_i$  为真实目标个数,  $n$  为测试视频帧个数。

## 3 结果与分析

### 3.1 目标检测结果

#### 3.1.1 不同网络模型对比

为验证检测方法 YOLO11-PMSL 在柑橘果实数据集上的检测性能,本文将其与当前主流轻量级目标检测模型开展全面对比试验,包括经典模型快速区域卷积神经网络 (faster region-based convolutional neural network, Faster-RCNN)、单次多框检测器 (single shot multibox detector, SSD) 以及 YOLO 系列轻量级模型 YOLOv8n<sup>[26]</sup>、YOLOv9 t<sup>[27]</sup>、YOLOv10n<sup>[28]</sup>、YOLO12n<sup>[29]</sup> 进行了对比试验。

由表 1 可知,本研究选用 YOLO11n 作为基准模型,在整体性能方面优于其他基础模型。改进后的轻量化 YOLO11-PMSL 模型与其他主流的轻量化模型相比,在柑橘果实数据集测试中,模型的各项性能表现出色,其关键性指标  $mAP_{0.5}$  比 Faster-RCNN、SSD、YOLOv8n、YOLOv9 t、YOLOv10n 和 YOLO12n 分别高出 25.9、14.0、12.7、9.7、9.9 和 11.7 个百分点;参数量分别降低了 99.13%、98.48%、86.57%、79.19%、84.07% 和 85.66%;浮点运算量分别减少了 129.4、209.4、2.2、1.8、1.9 和 1.2 G;模型大小分别下降了 99.72%、99.52%、76.79%、69.05%、77.59% 和 75%。

表 1 不同模型柑橘果实检测结果

Table 1 Results of citrus fruit testing using different models

| 模型<br>Models | 精度<br>Precision<br>$P/\%$ | 召回率<br>Recall<br>$R/\%$ | $mAP_{0.5}/\%$ | 参数量<br>Parameters<br>$P_d/M$ | 浮点运算数<br>FLOPs/<br>G | 模型大小<br>Modes<br>size/<br>MB | FPS/<br>(帧·s <sup>-1</sup> ) |
|--------------|---------------------------|-------------------------|----------------|------------------------------|----------------------|------------------------------|------------------------------|
| FasterRcnn   | 68.9                      | 53.4                    | 64.6           | 41.35                        | 134                  | 472.1                        | 30.9                         |
| SSD          | 73.7                      | 75.9                    | 76.5           | 23.75                        | 214                  | 272.1                        | 24.8                         |
| YOLOv8n      | 78.6                      | 70.3                    | 77.8           | 2.68                         | 6.8                  | 5.6                          | 82.83                        |
| YOLOv9 t     | 79.6                      | 74.4                    | 80.8           | 1.73                         | 6.4                  | 4.2                          | 87.06                        |
| YOLOv10n     | 82.8                      | 69.4                    | 80.6           | 2.26                         | 6.5                  | 5.8                          | 85.46                        |
| YOLO11n      | 83.0                      | 71.4                    | 81.2           | 2.58                         | 6.3                  | 5.5                          | 84.83                        |
| YOLO12n      | 80.7                      | 70.6                    | 78.8           | 2.51                         | 5.8                  | 5.2                          | 75.49                        |
| YOLO11-PMSL  | 86.3                      | 83.0                    | 90.5           | 0.36                         | 4.6                  | 1.3                          | 140.12                       |

同时, YOLO11-PMSL 的帧率优于其他模型。这表明 YOLO11-PMSL 实现了检测精度与模型轻量化之间的双重优化,保证模型的实用性。改进模型实现对复杂场景下柑橘果实的高精度识别,同时,低参数量与计算量使模型具备部署边缘计算平台的能力,显著降低硬件成本与数据传输延迟,为智慧果园构建的产量监测体系提供技术支撑。

#### 3.1.2 模型剪枝率对比结果

为评估结构化剪枝对 YOLO11-PMSL 模型的影响,对 YOLO11-PMSL 模型进行渐进式压缩对比试验。剪枝率定义为模型剪枝前后计算量之比:剪枝率为 1.0 时,表示基准模型,剪枝率为 2.0 则表明计算量降低 50%。

每次剪枝后执行微调训练以补偿精度损失。剪枝率的设置范围从 1.6 到 2.4，步长为 0.2。

由表 2 可知，当剪枝率在 1.6 时，模型参数量、浮点运算量和体积均明显缩减，精度明显上升，而召回率出现明显下降，帧速率明显提升。随着剪枝率的提升，模型参数量、浮点运算量和体积均持续下降，召回率和  $mAP_{0.5}$  先上升后又下降，而帧速率一直降低。当剪枝率达到 2.2 时，成功实现性能表现与轻量化的最优平衡。此时  $mAP_{0.5}$  达到 90.5%，参数量精简至 0.36 M，模型体积压缩至 1.3 MB，计算复杂度降至 4.6 G，帧速率提升至 140.12 帧/s。相较于原始模型，该剪枝方案在模型关键性能指标上无差异，而在轻量化上正向提高，验证了适度剪枝可协同优化效率与精度。基于综合评价，最终选定剪枝率在 2.2 为最优剪枝强度。

表 2 模型剪枝率对比结果

Table 2 Comparison of model pruning rates

| 剪枝率<br>Pruning rate | P/%  | R/%  | $mAP_{0.5}/\%$ | $P_d/M$ | FLOPs/G | 模型大小<br>Modes size/MB | FPS/(帧·s <sup>-1</sup> ) |
|---------------------|------|------|----------------|---------|---------|-----------------------|--------------------------|
| 1.0                 | 85.2 | 83.8 | 90.6           | 1.21    | 10.4    | 3.1                   | 73.68                    |
| 1.6                 | 87.9 | 81.2 | 90.4           | 0.48    | 6.3     | 1.5                   | 136.96                   |
| 1.8                 | 87.1 | 81.4 | 90.7           | 0.44    | 5.6     | 1.4                   | 128.86                   |
| 2.0                 | 88.4 | 80.1 | 90.5           | 0.41    | 5.0     | 1.4                   | 122.96                   |
| 2.2                 | 86.3 | 83.0 | 90.5           | 0.36    | 4.6     | 1.3                   | 140.12                   |
| 2.4                 | 87.0 | 80.9 | 90.0           | 0.34    | 4.2     | 1.2                   | 155.14                   |

### 3.1.3 消融试验结果

为解析模型架构调整的有效性，本研究对 YOLOv11-PCMS 框架实施渐进式消融分析。试验设计以基准模型为起点，首先重构特征金字塔层级为 P2~P4 精简结构，其次引入多尺度边缘增强单元 (C3k2\_MSEIE)，再采用 SIOU 边界框回归损失替代原损失函数，最后对模型实施 LAMP 剪枝操作，生成轻量化模型。该消融策略的系

统性验证结果如表 3 所示。

由表 3 可知，在原始 YOLO11n 目标检测模型增加 P2 检测头后，模型的召回率以及  $mAP_{0.5}$  得到了大幅提升，然而模型的浮点运算量也大幅增长，增加计算负荷。通过解耦冗余的 P5 检测模块及其关联卷积层，重构特征金字塔为 P2~P4 三级检测结构后，与原始模型相比模型参数量下降了 55%，模型体积压缩至 2.6 MB，模型的召回率和  $mAP_{0.5}$  有了明显的上升，分别提高了 7.9，5.1 个百分点，说明重构后模型更轻量，对小目标检测更加准确。但模型浮点运算数上升了 55.5%，不满足轻量化需求。叠加 C3k2\_MSEIE 边缘增强模块后，性能得到进一步提升，模型精度、召回率以及  $mAP_{0.5}$ ，较原始模型分别上升了 2.2、10.7 和 8.7 个百分点。模型的参数量与浮点运算数较 YOLO11n+P2 有小幅度上升。将损失函数由 Clou 更换为 SIOU 后，模型的召回率上升了 12.4 个百分点， $mAP_{0.5}$  上升了 9.4 个百分点，速率下降了 13.14%。此时，模型在目标检测的关键指标上表现出了最优的性能，但由于引入 P2 检测层不可避免的增加了模型的计算量，为满足边缘终端部署的轻量化需求，将模型进行 LAMP 剪枝操作，剪枝后模型在核心性能指标维持剪枝前的基准水平，模型的参数量、浮点运算量，以及模型大小较剪枝前大幅度下，分别下降了 70.25%、55.77% 和 58.06%。最终在目标检测方面，与原始 YOLO11n 模型相比，模型精度、召回率和  $mAP_{0.5}$  分别提高 3.3、11.6 和 9.3 个百分点；在模型轻量化方面，与原始模型相比参数量、模型大小，以及浮点运算量分别降低 86.05%、76.36% 和 26.98%；在检测速度方面，与原模型相比，速率提升了 65.18%，说明改进的 YOLO11-PMSL 模型在柑橘果实数据集上达到检测精度和速度的双重提升。

表 3 YOLO11n 模型在柑橘果实检测上的消融试验结果

Table 3 Ablation experiment results of YOLO11n model on citrus fruit detection

| 模型<br>Models                                                    | P/%  | R/%  | $mAP_{0.5}/\%$ | $P_d/M$ | FLOPs/G | 模型大小<br>Modes size/MB | FPS/(帧·s <sup>-1</sup> ) |
|-----------------------------------------------------------------|------|------|----------------|---------|---------|-----------------------|--------------------------|
| YOLO11n                                                         | 83.0 | 71.4 | 81.2           | 2.58    | 6.3     | 5.5                   | 84.83                    |
| YOLO11n+P <sub>2345</sub>                                       | 83.8 | 78.2 | 87.4           | 2.67    | 10.3    | 5.9                   | 58.32                    |
| YOLO11n+P <sub>234</sub>                                        | 81.8 | 79.3 | 86.3           | 1.16    | 9.8     | 2.6                   | 60.49                    |
| YOLO11n+P <sub>234</sub> +C3k2_MSEIE                            | 85.2 | 82.1 | 89.9           | 1.21    | 10.4    | 3.1                   | 73.52                    |
| YOLO11n+P <sub>234</sub> +C3k2_MSEIE+SIOU                       | 85.2 | 83.8 | 90.6           | 1.21    | 10.4    | 3.1                   | 73.68                    |
| YOLO11n+P <sub>234</sub> +C3k2_MSEIE+SIOU<br>+LAMP(YOLO11-PMSL) | 86.3 | 83.0 | 90.5           | 0.36    | 4.6     | 1.3                   | 140.12                   |

注：P<sub>2345</sub> 为添加小目标检测层，P<sub>234</sub> 为优化的目标检测层

Note: P<sub>2345</sub> adds a small object detection layer, P<sub>234</sub> is an optimized small object detection layer


### 3.1.4 可视化分析

为验证 YOLO11-PMSL 模型在柑橘果实检测任务中的特征聚焦特性，本研究采用梯度加权类激活映射 (Grad-CAM<sup>[30]</sup>) 技术对比 YOLO11n 基准模型与 YOLO11-PMSL 改进模型的关键区域响应模式。如图 9 所示的热力图可视化结果中，特征激活强度通过色谱梯度表征，可观察到 YOLO11n 基准模型的热力图 (图 9b) 多存在局部离散分布的黄色中强度响应区，且目标与目标之间红色区域出现粘连现象；相比之下，改进模型 (图 9c) 对果实目标更具关注度，位置多呈现红色和黄色信号，且相邻果实间激活边界清晰可辨，同时图 9b 中基准模型对特定果实未生成显著激活响应的现象，与实际检测中的漏检行为形成空间关联。可见，本研究所构建的 YOLO11-PMSL

模型对果实目标关注力高，证明改进模型的优越性高。

### 3.1.5 模型检测结果


为验证 YOLO11-PMSL 架构在复杂果园场景下的检测性能，本研究随机抽取测试集与验证集样本进行可视化验证 (图 10)。对比分析表明，在强光和阴天两种典型光照环境下，原始 YOLO11 模型主要存在两类典型局限，首先是在高密度果实区域中出现明显漏检，特别是对于枝叶遮挡的果实，检测完整性较差；在强光场景中易受高反射与过曝影响，出现部分果实目标特征模糊或丢失，导致漏检率较高；其次是存在误检情况，常将叶片、果皮反光或地面高亮区域误判为柑橘果实，并且对同一果实可能生成多个检测框。同时，在阴天的情况下，则因果实与背景对比度较低而产生一定的误检。



注：红色：高响应；蓝色：低响应。

Note: Red: High response; Blue: Low response.

图9 YOLO11 和 YOLO11-PMSL 柑橘检测热点图  
Fig.9 YOLO11 and YOLO11-PMSL citrus detection heat map



注：红色框表示漏检，黄色框表示误检。

Note: Red boxes indicate missed detection, and yellow boxes indicate false detection.

图10 YOLO11 和 YOLO11-PMSL 柑橘果实检测结果对比  
Fig.10 Comparison of citrus fruit detection results between YOLO11 and YOLO11-PMSL

相比之下，改进后的 YOLO11-PMSL 模型优势明显。其密集区域的漏检率降低，对微小及部分遮挡果实的检出能力得到明显提升。同时误检率明显降低，对果实识别的准确度较高，不易将背景或反光物体误检测为果实。综上，YOLO11-PMSL 模型在复杂光照与遮挡条件下均展现出更高的检测精度与稳定性。

### 3.2 果实跟踪与计数

使用 SORT<sup>[31]</sup>、DeepSORT<sup>[32]</sup>、Bot-SORT<sup>[33]</sup> 和 ByteTrack<sup>[34]</sup> 四种跟踪模型结合 YOLO11-PMSL 分别实现柑橘果实目标跟踪计数，跟踪计数结果如表4所示。

由表4可知，YOLO11-PMSL 结合 ByteTrack 的集成模型展现出优异跟踪性能，相较于同检测模型搭载

SORT、DeepSORT 与 Bot-SORT 的方案，多目标跟踪准确率（MOTA）指标分别高出 3.3、3.5 和 2.1 个百分点，跟踪精确率（MOTP）分别高于 13.2、13.4 和 7.8 个百分点，验证 ByteTrack 在复杂果园环境中的优势。在身份识别 F1 分数关键指标上，该模型的 F1 分数为 90.8%，同样优于对比算法。而 YOLO11-PMSL 结合 ByteTrack-DIoU 的集成模型展现出最优的跟踪性能，其多目标跟踪准确率（MOTA）达 92.8%，跟踪精确率（MOTP）为 81.7%。相较 YOLO11-PMSL 搭载 ByteTrack 的方案，多目标跟踪准确率（MOTA）提升 2.2 个百分点，跟踪精确率（MOTP）提升 3 个百分点，在身份识别 F1 分数指标提升 1.2 个百分点。

表4 不同模型跟踪计数结果

| Table 4 Tracking and counting results of different models (%) |                                                      |                                                      |                                             |
|---------------------------------------------------------------|------------------------------------------------------|------------------------------------------------------|---------------------------------------------|
| 模型<br>Models                                                  | 多目标跟踪<br>准确率<br>Multiple object<br>tracking accuracy | 多目标跟踪<br>精确率<br>Multiple object<br>tracking accuracy | 身份识别<br>F1 分数<br>Identification<br>F1 Score |
|                                                               | RMOTA                                                | RMOTP                                                | IDF1                                        |
|                                                               |                                                      |                                                      |                                             |
| YOLO11-PMSL+SORT                                              | 87.3                                                 | 62.5                                                 | 86.4                                        |
| YOLO11-PMSL+DeepSORT                                          | 87.1                                                 | 62.3                                                 | 89.0                                        |
| YOLO11-PMSL+Bot-SORT                                          | 88.5                                                 | 70.9                                                 | 90.6                                        |
| YOLO11-PMSL+ByteTrack                                         | 90.6                                                 | 78.7                                                 | 90.8                                        |
| YOLO11-PMSL+<br>ByteTrack-DIoU                                | 92.8                                                 | 81.7                                                 | 92.0                                        |

针对航拍视频中柑橘目标因尺度动态变化与枝叶遮挡导致的身标识漂移（ID Switch）问题，本研究在 ByteTrack 框架中引入区域计数机制。该设计通过建立空间位置约束规则，有效关联被遮挡目标的跨帧轨迹，消除因 ID 跳变引发的计数累积误差。为验证该计数策略的准确性，本文随机抽取 5 个（视频 1~5 分别对应第 1、2、3、5、8 行柑橘果树）不同的视频上进行的试验，并将结果与人工计数进行了对比，结果如表5所示，改进后模型计数结果与人工统计值的差异缩小，平均计数精度提高至 88.4%。综合考虑跟踪性能（表4）与计数精度（表5）的量化结果，本研究所提算法在柑橘果实统计中与人工统计结果偏差小于 12%，满足实际需求。区域计数机制的解决复杂场景下的 ID 稳定性问题，满足果园估产对计数鲁棒性与精确性的双重需求。

表5 不同计数方法的计数结果

| Table 5 Counting results of different counting methods |                 |                 |                 |                 |                                       |
|--------------------------------------------------------|-----------------|-----------------|-----------------|-----------------|---------------------------------------|
| 模型<br>Models                                           | 视频 1<br>Video 1 | 视频 2<br>Video 2 | 视频 3<br>Video 3 | 视频 4<br>Video 4 | 视频 5<br>Video 5                       |
| 人工计数<br>Manual counting                                | 970             | 1 522           | 963             | 899             | 860                                   |
| YOLO11-PMSL+<br>ByteTrack-DIoU                         | 859             | 1 317           | 854             | 799             | 770                                   |
|                                                        |                 |                 |                 |                 | 平均计数精度<br>Mean counting<br>accuracy/% |
|                                                        |                 |                 |                 |                 | 88.4                                  |

## 4 结 论

本研究提出融合 YOLO11-PMSL 检测模型与 ByteTrack-DIoU 算法的集成框架, 实现在复杂果园环境下的柑橘果实高效检测与精准计数, 具体结论如下:

1) 检测模型 YOLO11-PMSL 在柑橘数据集上的检测精度超越基准模型。经对 YOLO11n-PCMS 模型剪枝过后, 模型更加轻量化, 参数量、浮点运算量及模型体积较原始 YOLO11n 分别压缩了 2.2 M、1.7 G 与 4.2 MB, 帧率提高到 140.12 帧/s, 证实其在精度与效率上的双重突破。

2) 跟踪算法上 YOLO11-PMSL 和 ByteTrack-DIoU 组合实现最优跟踪性能, 多目标跟踪准确率达到 92.8%、跟踪精确率为 81.7%, 与传统 SORT、DeepSORT 和 BotSORT 算法相比, ByteTrack-DIoU 算法多目标跟踪准确率分别提高 5.5、5.7 和 4.3 个百分点, 表明 YOLO11-PMSL 结合 ByteTrack-DIoU 跟踪性能更加优异。

3) 针对 ID 跳变引发的计数误差, 设计区域计数与防抖协同机制, 将平均计数精度提升至 88.4%, 与人工统计结果偏差小于 12%, 满足实际需求。

该方法实现了复杂果园环境下 88.4% 平均计数精度的柑橘果实实时预测, 为智慧果园精准管理提供了可靠的技术支撑。

## [参 考 文 献]

- JIBRIL DAAIEDDINE M, BADROUSS S, EL HARTI A, et al. UAV imagery, advanced deep learning, and YOLOv7 object detection model in enhancing citrus yield estimation[J]. *Foods and Raw Materials*, 2025: 13(2): 242-253.
- TRAN C C, NGUYEN D T, LE H D, et al. Automatic dragon fruit counting using adaptive thresholds for image segmentation and shape analysis[C]//2017 4th NAFOSTED Conference on Information and Computer Science. Hanoi, Vietnam. IEEE, 2017: 132-137.
- BEHERA S K, MISHRA N, SETHY P K, et al. On-tree detection and counting of apple using color thresholding and CHT[C]// 2018 International Conference on Communication and Signal Processing (ICCSP). Chennai, India. IEEE, 2018: 0224-0228.
- ZHU Y H, LIU F, ZHAO Y Y, et al. Citrus yield estimation for individual trees integrating pruning intensity and image views[J]. *European Journal of Agronomy*, 2024, 161(11): 127349.
- LI P, ZHENG J, Li P, et al. Tomato maturity detection and counting model based on MHSA-YOLOv8[J]. *Sensors*, 2023, 23(15): 6701.
- ZINE-EL-ABIDINE M, DUTAGACI H, GALOPIN G, et al. Assigning apples to individual trees in dense orchards using 3D colour point clouds[J]. *Biosystems Engineering*, 2021, 209: 30-52.
- ZHANG C, ZHANG K, GE L, et al. A method for organs classification and fruit counting on pomegranate trees based on multi-features fusion and support vector machine by 3D point cloud[J]. *Scientia Horticulturae*, 2021, 278: 109791.
- WANG Z, WALSH K, KOIRALA A. Mango fruit load estimation using a video based MangoYOLO—Kalman filter—hungarian algorithm method[J]. *Sensors*, 2019, 19(12): 2742.
- 高芳芳, 武振超, 索睿, 等. 基于深度学习与目标跟踪的苹果检测与视频计数方法[J]. *农业工程学报*, 2021, 37(21): 217-224.
- GAO Fangfang, WU Zhenchao, SUO Rui, et al. Apple detection and counting using real-time video based on deep learning and object tracking[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2021, 37(21): 217-224. (in Chinese with English abstract).
- GE Y, LIN S, ZHANG Y, et al. Tracking and counting of tomato at different growth period using an improving YOLO-deepsort network for inspection robot[J]. *Machines*, 2022, 10(6): 489.
- VIVEROS ESCAMILLA L D, GÓMEZ-ESPINOSA A, ESCOBEDO CABELLO J A, et al. Maturity recognition and fruit counting for sweet peppers in greenhouses using deep learning neural networks[J]. *Agriculture*, 2024, 14(3): 331.
- LIN Y H, HU W X, ZHENG Z H, et al. Citrus identification and counting algorithm based on improved YOLOv5s and DeepSort[J]. *Agronomy-Basel*, 2023, 13(7): 1674.
- ZHENG Z H, WU M, CHEN L, et al. A robust and efficient citrus counting approach for large-scale unstructured orchards[J]. *Agricultural Systems*, 2024, 215(3): 103867.
- 殷慧军, 王宝丽, 景运革, 等. 基于改进 YOLOv7 的无人机航拍视频西瓜计数方法[J]. *农业工程学报*, 2024, 40(19): 124-134.
- YIN Huijun, WANG Baoli, JING Yunge, et al. Improved YOLOv7 method for counting watermelons in UAV aerial videos[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(19): 124-134. (in Chinese with English abstract).
- 吕佳, 张翠萍, 刘琴, 等. 基于自纠正 NMS-ByteTrack 的套袋葡萄估产方法[J]. *农业工程学报*, 2023, 39(13): 182-190.
- LYU Jia, ZHANG Cuiping, LIU Qin, et al. Method for estimation of bagged grape yield using a self-correcting NMS-ByteTrack[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(13): 182-190. (in Chinese with English abstract).
- 刘鑫, 马本学, 李玉洁, 等. 基于改进 YOLOv7-ByteTrack 的干制哈密大枣缺陷检测与计数系统[J]. *农业工程学报*, 2024, 40(3): 303-312.
- LIU Xin, MA Benxue, LI Yujie, et al. Detecting and counting defects in dried Hami jujube using improved YOLOv7-ByteTrack[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(3): 303-312.
- 吕佳, 张翠萍. 基于 EMO-YOLOv5s 的双关联套袋葡萄串实时检测与计数[J]. *农业工程学报*, 2025, 41(12): 161-171.
- LYU Jia, ZHANG Cuiping. Real-time detecting and counting dual-association bagged grape clusters using EMO-YOLOv5s[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(12): 161-171.
- KHANAM R, HUSSAIN M. YOLOv11: An overview of the key architectural enhancements[EB/OL]. (2024-10-23)[2025-04-25]. <https://www.arxiv.org/abs/2410.17725>.
- ZHENG Z H, WANG P, REN D W, et al. Enhancing Geometric factors in model learning and Inference for object detection and instance segmentation[J]. *IEEE Transactions on Cybernetics*, 2022, 52(8): 8574-8586.
- GEVORGYAN Z. SloU loss: More powerful learning for bounding box regression[EB/OL]. (2022-05-25)[2025-08-06]<https://arxiv.org/abs/2205.12740>.
- LEE J, PARK S, MO S, et al. Layer-adaptive sparsity for the magnitude-based pruning[EB/OL]. (2020-10-15)[2025-08-06]<https://arxiv.org/abs/2010.07611>.
- 黄鹤飞. 一种改进 YOLOv8 和 StrongSORT 的车流量检测方法[D]. 石家庄: 石家庄铁道大学, 2025.
- HUANG Hefei. A Traffic Flow Counting Method Based on Improved YOLOv8 and StrongSORT Algorithms[D]. Shijiazhuang: Shijiazhuang Tiedao University, 2025. (in Chinese with English abstract).
- 涂淑琴, 黄磊, 梁云, 等. 基于 JDE 模型的群养生猪多目标跟踪[J]. *农业工程学报*, 2022, 38(17): 186-195.
- TU Shuqin, HUANG Lei, LIANG Yun, et al. Multiple object tracking of group-housed pigs based on JDE model[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2022, 38(17): 186-195. (in Chinese with English abstract).
- 吕佳, 冉洁. 基于改进 YOLOv9s 与自适应卡尔曼滤波的套袋葡

- 萄视频计数方法[J]. 农业工程学报, 2025, 41(10): 195-203. LYU Jia, RAN Jie. Counting bagging grape using improved YOLOv9s and adaptive Kalman filter[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(10): 195-203. (in Chinese with English abstract).
- [25] 郭明月, 刘雅晨, 李伟夫, 等. 基于视频跟踪算法的果园猕猴桃产量实时预估[J]. 农业机械学报, 2023, 54(6): 178-185. GUO Mingyue, LIU Yachen, LI Weifu, et al. Real-time production prediction of kiwifruit in orchard based on video tracking algorithm[J]. Transactions of the Chinese Society for Agricultural Machinery, 2023, 54(6): 178-185. (in Chinese with English abstract).
- [26] LOU H, DUAN X, GUO J, et al. DC-YOLOv8: Small-size object detection algorithm based on camera sensor[J]. *Electronics*, 2023, 12(10): 2323.
- [27] WANG C Y, YEH I H, LIAO M H Y. YOLOv9: Learning what you want to learn using programmable gradient information[A]. European conference on computer vision[C]. Cham: Springer Nature Switzerland, 2024.
- [28] PAN W, CHEN J, LV B, et al. Lightweight marine biodetection model based on improved YOLOv10[J]. *Alexandria Engineering Journal*, 2025, 119: 379-390.
- [29] TIAN Y, YE Q, DOERMANN D. Yolov12: Attention-centric real-time object detectors[EB/OL]. (2025-02-18)[2025-04-25]. <https://arxiv.org/abs/2502.12524>.
- [30] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-cam: visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE international conference on computer vision. Venice, Italy, 2017: 618-626.
- [31] 杜磊. 基于 SORT 算法的图像轨迹跟踪混合控制方法[J]. 现代电子技术, 2024, 47(13): 32-35. DU Lei. Image trajectory tracking hybrid control method based on SORT algorithm[J]. *Modern Electronic Technique*, 2024, 47(13): 32-35. (in Chinese with English abstract).
- [32] WOJKE N, BEWLEY A, PAULUS D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE International Conference on Image Processing. Beijing, China: IEEE, 2017: 3645-3649.
- [33] AHARON N, ORFAIG R, BOBROVSKY B Z. BoT-SORT: Robust associations multi-pedestrian tracking[EB/OL]. (2022-06-29)[2025-08-06]<https://arxiv.org/abs/2206.14651>.
- [34] ZHANG Y, SUN P, JIANG Y, et al. Bytetrack: Multi-object tracking by associating every detection box[C]// European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 1-21.

## Citrus tracking and counting using UAV remote sensing video imagery with improved YOLO11

WENG Haiyong<sup>1,2,3</sup>, DU Lu<sup>1,2</sup>, ZHANG Boyu<sup>1,2</sup>, SU Leilei<sup>1,2</sup>, XU Jinchai<sup>1,2</sup>,  
XIAO Guimiao<sup>1,2</sup>, SUN Dawei<sup>3,4</sup>, YE Dapeng<sup>1,2\*</sup>

(1. College of Mechanical and Electrical Engineering, Fujian Agriculture and Forestry University, Fuzhou 350002, China; 2. Fujian Key Laboratory of Agricultural Information Sensing Technology, Fuzhou 350002, China; 3. Key Laboratory of Agricultural Equipment for Hilly and Mountainous Areas in Southeastern China (Co-construction by Ministry and Province), Ministry of Agriculture and Rural Affairs, Hangzhou 310021, China; 4. Institute of Agricultural Equipment, Zhejiang Academy of Agricultural Sciences, Hangzhou 310021, China)

**Abstract:** Citrus yield estimation is often required for low missed detection rates, tracking, and counting errors using UAV remote sensing, particularly for dense fruit occlusion and small target size. In this study, citrus tracking and counting were proposed using UAV remote sensing video imagery with improved YOLO11. The video data was first collected by a DJI Phantom 4 UAV at an angle of approximately 45°. A citrus target detection was constructed on the tracking dataset. An automatic citrus counting was realized using UAV video streams. A lightweight YOLO11-PMSL model was combined with an improved ByteTrack algorithm. The detection head layer was simplified to a three-level structure (P2-P4) using the YOLO11n network architecture. The feature pyramid structure was reconstructed. Deep redundant modules were removed to fuse the high-resolution shallow features, and then perceive small targets. Secondly, the C3k2-MSEIE multi-scale edge module was introduced after adaptive scale fusion and contour enhancement. The local details were expressed to extract the fruit contours. The overall morphological features of the fruit were preserved, with better feature expression in the densely populated fruit areas. Subsequently, the loss function was replaced by SIoU. A direction-sensitive constraint was introduced to improve the localization accuracy and training stability of the detection boxes. Finally, the LAMP was used to prune the model for the removal of redundant weights. The number of parameters and floating-point operations was then reduced to compress the model size for model lightweighting. The ByteTrack algorithm framework was improved, rather than using IoU in spatial location measurement. The accuracy and stability of fruit tracking were further enhanced in complex orchard environments. The similarity metric in ByteTrack was replaced with the DIoU. Simultaneously, a region-counting anti-shake mechanism was embedded in the algorithm. The target ID jump problem under occlusion was effectively solved for the accurate counting of citrus fruits. Experimental results showed that the YOLO11-PMSL model effectively improved the performance of the model. Specifically, compared with the original YOLO11n object model, better performance was achieved in the feature pyramid into a P2-P4 three-level structure. The number of model parameters was reduced to 116 m, the model size was compressed to 2.6 MB, and the recall and mAP0.5 metrics were significantly improved by 7.9 and 5.1 percentage points, respectively. The more lightweight model was verified by the higher accuracy for small targets. The precision, recall, and mAP0.5 were improved by 2.2, 10.7, and 8.7 percentage points, respectively, with the C3k2-MSEIE edge module. Once the loss function was replaced from CIoU to SIoU, the convergence speed was accelerated to further improve its performance. The LAMP algorithm was used to prune the model, fully meeting the lightweight deployment of edge terminals. The performance remained at the baseline level before pruning. While the number of parameters, floating-point operations, and model size were significantly reduced from before. Ultimately, the precision, recall, and mAP0.5 were improved by 3.3, 11.6, and 9.3 percentage points, respectively, in the object detection task. In terms of lightweighting, the number of parameters, model size, and floating-point operations were reduced by 86.05%, 76.36%, and 26.98%, respectively, compared with the original model. The detection speed was improved by 65.18%. The YOLO11-PMSL model achieved a detection accuracy and speed on the citrus dataset. In the object tracking task, the ByteTrack multi-object tracking algorithm achieved an accuracy of 92.8% and a tracking precision of 81.7%. Compared with the SORT, DeepSORT, and BotSort algorithms, the tracking accuracy was improved by 5.5, 5.7, and 4.3 percentage points, respectively, and the tracking precision was improved by 19.2, 19.4, and 10.8 percentage points, respectively. The average accuracy of citrus counting reached 88.4%, compared with manual counting. The counting error was smaller than that of manual counting. Citrus counting was effectively realized in farmland scenarios. This finding can provide a technical approach for citrus yield prediction.

**Keywords:** UAV; remote sensing; citrus; YOLO11n; ByteTrack; counting